

République Algérienne Démocratique et Populaire
Ministère de l'enseignement Supérieur et de la Recherche Scientifique
Université de Mohamed El Bachir El Ibrahimi de Bordj Bou Arréridj
Faculté des Mathématiques et d'Informatique
Département d'informatique



MEMOIRE

Présenté en vue de l'obtention du diplôme

Master en informatique

Spécialité : Technologie de l'information et de la communication

THEME

Génération de carte d'occupation du sol à partir de série temporelle d'images satellitaire

Présenté par :

BOUGHABA Adnane

CHELALI Anis

REZIG Ayoub

Soutenu publiquement le : 26/06/2024

Devant le jury composé de :

Président : NOUIOUA Farid

Examinateur : BEGHOURA Mohamed Amine

Représentante de l'incubateur : LOUKRISE Soumia

Encadreur : ATTIA Safa

2023/2024

Remerciements

Nous tenons à remercier en premier lieu notre encadrante Mme ATTIA Safa, qui a su nous guider et diriger tout au long de ce mémoire. Elle s'est pleinement investie pour nous fournir un climat de travail confortable et satisfaisant, tant au niveau matériel qu'intellectuel.

Nous souhaitons également adresser nos sincères remerciements aux membres du jury, Dr.FARID Nouioua, Dr.BEGHOURA Mohamed Amine, pour avoir accepté d'évaluer notre travail.

Nous tenons également à remercier nos amis, qui nous ont encouragés à aller de l'avant.

Nous ne saurions oublier Mohamed Tayeb Chelali pour ces contributions qui ont été un plus pour la compréhension du projet.

Enfin, un grand “ merci ” à nos parents, sœurs et frères, qui nous ont toujours soutenus et supportés. Leur aide et leurs encouragements ont été très précieux dans nos choix, parfois difficiles, tout au long de nos parcours universitaire.

Hommage au papa de Anis

Je dédie personnellement ce projet à la mémoire de mon père, dont l'inspiration et les valeurs continuent de guider mes pas. Son exemple de détermination et de bienveillance reste gravé dans mon cœur et mon esprit. Papa, ce travail est un hommage à ton amour, à ta sagesse et à ta foi inébranlable en mes capacités. Ton souvenir m'accompagne chaque jour, et c'est avec une immense gratitude que je te dédie ce mémoire.

Résumé

L'évolution technologique a considérablement augmenté le nombre de satellites lancés dans l'espace pour l'observation de la Terre. Cela a également permis aux chercheurs de développer de nouvelles méthodes automatisées pour produire des cartographies d'occupation du sol. Ce type de données est particulièrement fréquent dans le domaine de la télédétection. Le choix des données est crucial et l'analyse ainsi que l'interprétation de ces données constituent un défi majeur. Ce mémoire s'inscrit dans le contexte de l'exploitation de ces données pour les classifier, en maximisant l'utilisation des informations des séries temporelles d'images satellitaires (*STIS*) qui offrent une richesse d'informations qu'elles contiennent, permettant ainsi une meilleure compréhension. Les travaux de recherche présentés dans ce rapport incluent deux méthodes distinctes ayant pour objectif commun la génération de cartes d'occupation des sols (*Toulouse et Algérie* comme cas d'études). La première méthode repose sur l'application de techniques d'apprentissage machine, tandis que la deuxième utilise des méthodes d'apprentissage profond, notamment les Réseaux de Neurones Convolutifs (*CNN*). Nous nous proposons d'étudier la crédibilité de ces deux familles de méthodes pour la génération de carte d'occupation du sol.

Mots clés : Séries temporelles d'images satellitaires, Carte d'occupation du sol, Réseaux de neurones convolutifs, Télédétection, Apprentissage machine, Apprentissage profond

ملخص

أدت التطورات التكنولوجية إلى زيادة كبيرة في عدد الأقمار الصناعية التي تم إطلاقها في الفضاء لرصد الأرض. وقد سمح هذا أيضاً للباحثين بتطوير طرق آلية جديدة لإنتاج خرائط الغطاء الأرضي. وهذا النوع من البيانات شائع بشكل خاص في مجال الاستشعار عن بعد. يعد اختيار البيانات أمراً بالغ الأهمية ويشكل تحليل هذه البيانات وتفسيرها تحدياً كبيراً. وتأتي هذه الرسالة في إطار استغلال هذه البيانات لتصنيفها، من خلال تعظيم استخدام المعلومات من السلاسل الزمنية لصور الأقمار الصناعية (STIS) التي توفر ثروة من المعلومات التي تحتوي عليها مما يسمح بفهم أفضل. يتضمن البحث المقدم في هذا التقرير طريقتين متميزتين لهدف مشترك وهو إنشاء خرائط الغطاء الأرضي (تولوز والجزائر كدراسات حالة). تعتمد الطريقة الأولى على تطبيق تقنيات التعلم الآلي، بينما تستخدم الثانية أساليب التعلم العميق، بما في ذلك الشبكات العصبية (CNN). نقترح دراسة مدى مصداقية هاتين العائلتين من الطرق لتوليد خرائط الغطاء الأرضي.

:

الكلمات المفتاحية

السلاسل الزمنية لصور الأقمار الصناعية، خرائط الغطاء الأرضي ، الشبكات العصبية ، الاستشعار عن بعد ، التعلم الآلي ، التعلم العميق

Abstract

Technological advancements have significantly increased the number of satellites launched into space for Earth observation. This has also enabled researchers to develop new automated methods for producing landcovers. Such data is particularly prevalent in the field of remote sensing. The choice of data is crucial, and the analysis and interpretation of this data constitute a major challenge. This thesis is set in the context of exploiting this data to classify it, by maximizing the use of information from satellite image time series (*STIS*) which offer a wealth of information contained, allowing for better understanding. The research presented in this report includes two distinct methods with the common objective of generating land covers (*Toulouse* and *Algeria* as case studies). The first method is based on the application of machine learning techniques, while the second method utilizes deep learning methods, specifically Convolutional Neural Networks. We aim to study the credibility of these two family of methods in the case of generation of land cover map.

Keywords : Satellite time series, Land cover, Convolutional neural networks, Remote sensing, Machine learning, Deep learning

Table des matières

Remerciements	ii
Résumé	iii
Résumé arabe	iv
Abstract	v
Liste des abréviations	viii
Liste des figures	x
Liste des tableaux	xi
1 Introduction	1
1.1 Contexte des travaux	1
1.2 Problématique	3
1.3 Objectif	3
1.4 Structure du rapport	4
2 Analyse de Séries Temporelles d'Images Satellites (STIS)	5
2.1 Méthode d'analyse des STIS	5
2.2 Méthode traditionnelle	6
2.2.1 Caractéristiques colorimétriques	6
2.2.2 Caractéristiques spatiales ou de textures	9
2.2.3 Caractéristiques temporelles	10
2.3 Méthode basées sur l'apprentissage profond	14
2.4 Synthèse	18
3 Génération de la carte d'occupation du sol	19
3.1 Définition des STIS	19
3.2 Présentation des données	20
3.3 protocole expérimentale	23
3.4 Résultats et discussions	26

4 Application web	32
4.1 Technologies Utilisées	32
4.2 Bibliothèque Leaflet et OpenStreetMap	32
4.3 Backend et FastAPI	33
4.4 Géoréférencement et Affichage Correct	34
4.5 Fonctionnalités de l'application	35
4.6 Améliorations Futures	35
5 Conclusion et perspectives	37
A Annexe	42
A.1 Axe 1 : Présentation du projet	45
A.1.1 Idée du projet	45
A.1.2 Valeurs proposées	45
A.1.3 Travail d'équipe	46
A.1.4 Objectifs du projet	46
A.1.5 Un échéancier pour la réalisation du projet	46
A.2 Axe 2 : les aspects innovant	47
A.3 Axe 3 : analyse stratégique du marché	47
A.3.1 Identification du Marché Cible et du Marché Potentiel	47
A.3.2 Mesure de l'Intensité de la Concurrence	47
A.3.3 Stratégies de Marketing	48
A.4 Axe 4 : le plan de production et d'organisation	49
A.4.1 Processus de Production	49
A.4.2 Approvisionnement	49
A.4.3 Main d'Œuvre	49
A.4.4 Identification des Principales Entreprises Participants au Projet	50
A.5 Axe 5 : le plan financier	51
A.5.1 Les Coûts	51
A.5.2 Chiffre d'affaire (APPROXIMATIVE)	51
A.6 Axe 6 : le prototype expérimental	53

Liste des abréviations

IA	Artificial Intelligence
STIS	Satellite Time Series
SOM	Self-Organizing Maps
ISODATA	Iterative Self-Organizing Data Analysis Technique
DTW	Dynamic Time Warping
KNN	K-Nearest Neighbors
SVM	Support Vector Machine
RF	Random Forest
NDVI	Normalized Difference Vegetation Index
PIR	Proche infrarouge
R	Rouge
V	Vert
B	Bleu
NDWI	Normalized Difference Water Index
IB	Brightness Index
SIFT	Scale-Invariant Feature Transform
HOG	Histogram of Oriented Gradients
LBP	Local Binary Patterns
GLCM	Gray-Level Co-Occurrence Matrix
PCA	Principal Component Analysis
RLE	Run-Length Encoding
HMM	Hidden Markov Models
HOG3D	3D Histogram of Oriented Gradients
3D-SIFT	3D Scale-Invariant Feature Transform
SURF	Speeded-Up Robust Features
eSURF	Extended Speeded-Up Robust Features
LTP	Local Ternary Patterns
RNN	Recurrent Neural Networks
CNN	Convolutional Neural Networks
TempCNN	Temporal Convolutional Neural Networks
GRU	Gated Recurrent Units
LSTM	Long Short-Term Memory
RP	Recurrence Plots
GAF	Gramian Angular Field
GASF	Gramian Angular Summation Field

GADF	Gramian Angular Difference Field
STFT	Short-Time Fourier Transform
RBF	Radial Basis Function
TC	Classification Rate
ET	Standard Deviation
IGN	National Institute of Geographic Information
INSEE	National Institute of Statistics and Economic Studies
ESA	European Space Agency
CESBIO	Centre d'Études Spatiales de la Biosphère
CNES	Centre National d'Études Spatiales
CESBIO	Centre d'Études Spatiales de la Biosphère
DLR	German Aerospace Center
SPOT-4	Satellite Pour l'Observation de la Terre
OSM	OpenStreetMap
HTML	Hypertext Markup Language
CSS	Cascading Style Sheets
FastAPI	Fast Application Programming Interface
JSON	JavaScript Object Notation
GDAL	Geospatial Data Abstraction Library
WGS 84	World Geodetic System 1984

Table des figures

1.1	Illustration des satellites : Spot-4, Landsat-8 et Sentinel-2.	2
2.1	Illustration d'une image Sentinel-2 avec différentes configurations des bandes spectrales et des différents indices de télédétection.	8
2.2	Illustration de deux exemples de caractéristiques. (a) visualisation des HOG pour la détection de bateaux ; (b) Schéma de génération d'un code LBP pour un pixel.	10
2.3	Illustration de la DTW et la mesure de stabilité.	12
2.4	Illustration de deux exemples de caractéristiques.(a) Aperçu du descripteur HOG3D , (b) Calcul de l'opérateur LTP.	13
2.5	Illustrations de l'architecture <i>RNN</i> , <i>LSTM</i> et <i>GRU</i>	14
2.6	Illustration de <i>TempCNN</i> (figure reprise de [1]).	15
2.7	Transformation d'une séquence temporelle en une matrice de <i>RP</i> . (Gauche) la séquence temporelle de longueur 12. (Milieu) plan 2D de l'espace des trajectoires. (Droite) la matrice résultante de <i>RP</i> de taille 11×11 [2].	16
2.8	Illustration des résultats visuels des <i>RP</i> , <i>GASF</i> , <i>GADF</i> et <i>STFT</i> sur deux séries temporelles issues de la base <i>GunPoint</i>	17
3.1	Image Sentinel-2 prise le 14/01/2023 avec son masque de nuage.	19
3.2	Chronologie des acquisitions pour les tuiles T31TCJ et T31SFA de l'année 2023	21
3.3	Illustration des différents classes de l'ensemble de données d'entraînement	22
3.4	Régions sélectionnées sur les tuiles T31TCJ et T31SFA.	23
3.5	Histogramme de la distribution des scores de confiance	24
3.6	Courbe d'apprentissage du modèle <i>TempCNN</i>	26
3.7	différence entre l'image depuis google earth et l'inférence du modèle TempCNN sur la région Toulouse	30
3.8	différence entre l'image depuis google earth et l'inférence du modèle TempCNN sur la région de Bejaia et BBA	31
4.1	Exemple d'intégration de Leaflet avec OpenStreetMap	33
4.2	Architecture du backend avec FastAPI	33
4.3	Principales fonctionnalités de l'application	36
A.1	Premier prototype de carte d'occupation du sol des deux régions	53
A.2	Présentation du premier prototype sur notre application web	54

Liste des tableaux

2.1	Définissions de bandes spectrales de Sentinel-2.	7
2.2	Mesures de textures basées sur GLCM.	9
3.1	Évaluation quantitave des modèles (Taux de classification – TC, écart-type – ET).	27
3.2	Résultats de la précision, le rappel et le f1-score de chaque classe des différents modèles.	28

Chapitre 1

Introduction

1.1 Contexte des travaux

Depuis des siècles, la connaissance de l'occupation des sols a été essentielle pour les sociétés. L'analyse de l'occupation des sols est un sujet essentiels pour le suivi et la compréhension de l'aménagement des terrains. Les premiers humains ont appris à identifier les terres propices à la culture, à différencier les zones forestières des terres agricoles, à trouver les emplacements appropriés pour développer les infrastructures et à gérer les ressources naturelles. L'évolution technologique, notamment l'introduction de l'imagerie satellitaire et de la télédétection, a révolutionné cette pratique en permettant une surveillance à grande échelle et une cartographie précise des terres. Les recherches mener dans ce rapport visent à la création d'une startup dénommée *Vita Earth*

L'évolution de la technologie a permis d'accroître le nombre de satellites lancés en espace pour l'observation de la Terre. Cela a aussi permis aux chercheurs de proposer de nouvelles méthodes qui fournissent des cartographies d'occupation du sol de manière automatique. De telles recherches ont permis le suivi de la couverture terrestre. Par exemple, l'Institut National de la Statistique et des Études Économiques (INSEE) de France avait compris qu'une artificialisation du territoire en 2017 induit à une perte de ressources en sol pour l'usage agricole et pour les espaces naturels.

La génération d'une carte d'occupation du sol à partir d'image satellitaire est une tâche cruciale. Le choix des données est la partie la plus importante. Pour ce faire, plusieurs satellites acquièrent des images sur le globe terrestre mais chacun à ses limites. D'un côté, il y a la zone géographique et d'un autre côté il y a la résolution spatiale. Par exemple satellite SPOT-4 a été lancé en 1998 mais il capte une image tous les 26 jours avec une résolution spatiale de 20 mètres. En 2013, un autre satellite nommé Landsat-8 a permis d'acquérir davantage d'images (chaque 16 jours) mais avec une résolution spatiale de 30 mètres. Récemment, le programme Copernicus de l'Agence spatiale européenne (ESA) a déployé le satellite Sentinel-2, constitué de deux satellites

identiques, Sentinel-2A et Sentinel-2B, Lancés respectivement en 2015 et 2017, ces satellites possèdent des caractéristiques remarquables pour l'observation de la Terre. Ils fournissent des séries temporelles d'images satellites (STIS) dans 13 bandes spectrales allant de la lumière visible au proche infrarouge, ainsi qu'une résolution spatiale allant de 10 à 60 mètres selon les bandes spectrales, et une résolution temporelle élevée permet une couverture régulière des mêmes zones tous les cinq jours [3]. La figure 1.1 illustre les satellites SPOT-4, Landsat-8 et Sentinel-2.

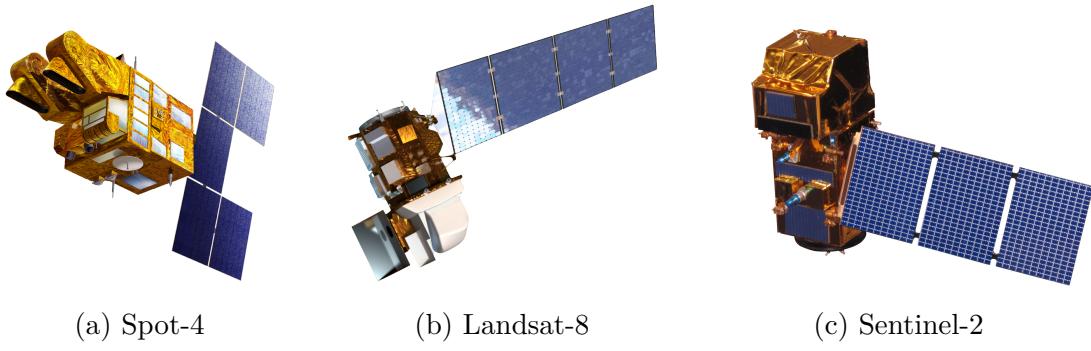


FIGURE 1.1 – Illustration des satellites : Spot-4, Landsat-8 et Sentinel-2.

L'occupation du sol décrit la couverture physique et biologique de la surface terrestre, qu'ils soient naturels ou artificiels [4]. Cette information revêt une importance cruciale pour de nombreux secteurs, notamment l'agriculture, l'aménagement du territoire, la gestion des ressources naturelles, la planification urbaine et la surveillance environnementale. Elle facilite également la compréhension et la gestion de phénomènes tels que la déforestation, fournissant ainsi des données précieuses pour orienter les efforts de préservation environnementale et de restauration des écosystèmes. Par exemple, Les cartes produites par l'Institut de Géographique National (IGN) permettent de cartographier précisément les types de sols, les cultures et les zones non cultivées, tout en suivant leur évolution au fil du temps. Ces cartes démontrent comment la cartographie de l'occupation du sol contribue à une agriculture durable et à la gestion efficace des terres entre agriculture et urbanisation [5].

En outre, la cartographie de l'occupation du sol joue un rôle essentiel dans la compréhension de la relation entre le changement climatique et l'évolution de la couverture terrestre. Cette connaissance est essentielle pour élaborer des politiques efficaces de lutte contre le changement climatique [6]. Elle est également utilisée dans la prévention des catastrophes, notamment dans les systèmes de modélisation tels que les modèles de propagation des inondations et des incendies [7, 8].

1.2 Problématique

La cartographie de l'occupation du sol est un outil essentiel pour la gestion du territoire national. Cependant, l'Algérie est confrontée à des défis majeurs dans ce domaine, notamment une urbanisation croissante qui entraîne une expansion rapide des zones urbaines, au détriment des terres agricoles et des écosystèmes naturels. La déforestation et la perte de biodiversité sont également des problèmes importants, amplifiés par la conversion des forêts en terres agricoles ou en zones urbaines. De plus, le manque de données précises est un obstacle majeur à la prise de décision, ce qui est crucial pour la planification et la gestion efficace des ressources. Enfin, il existe des conflits entre les différents usages des terres, tels que l'agriculture, l'urbanisation et la conservation.

1.3 Objectif

Dernièrement, plusieurs constellations satellitaires ont vu le jour produisant des séries temporelles d'images satellitaire à haut résolution spatiale et temporelle. Notre objectif est fondamentalement axé sur l'intégration de l'intelligence artificielle dans l'analyse des images satellitaires pour la production automatiquement des cartes d'occupation du sol. Grâce à l'apprentissage automatique, il est possible d'identifier et de classifier divers types de couvertures terrestres à partir d'images satellites. Ces algorithmes s'optimisent par rapport à un ensemble de données, dites données d'apprentissage, de manière automatique à distinguer les différentes zones telles que les zones urbaines, les terres agricoles et les zones forestières. Grâce à la nouvelle constellation de satellite Sentinel-2, nous avons l'accès à un ensemble de données important qui permet l'analyse de l'occupation du sol au fil du temps. Cette automatisation permet non seulement d'économiser du temps et des ressources précieuses, mais elle offre également des avantages en termes de précision et de cohérence des données. Les décideurs peuvent ainsi disposer de cartes actualisées et fiables pour prendre des mesures éclairées en matière de gestion des territoires.

Dans ce contexte, ce rapport se focalise sur la génération de carte d'occupation du sol en utilisant les méthodes d'intelligence artificielle, notamment les méthodes d'apprentissage automatique. Afin de montrer l'intérêt de ce type de méthodes, nous nous proposons de se comparer aux méthodes traditionnelles comme *Random Forest* qui est beaucoup utilisé pour la génération de carte d'occupation du sol. En examinant spécifiquement l'efficacité de la classification avec des modèles d'apprentissage profond pour la cartographie de l'occupation du sol. En comprenant comment ces méthodes peuvent être appliquées pour créer des cartes précises et actualisées, cette étude offre des perspectives concrètes pour une meilleure gestion des territoires, une prise de décision éclairée et des politiques environnementales et d'aménagement du territoire plus durables.

De plus, ce projet contribuera à combler le manque de données précises dans la prise de décision en fournissant des informations actualisées et fiables sur l'occupation du sol. Il offre ainsi une réponse directe aux besoins urgents des décideurs et des planificateurs en matière de gestion des ressources naturelles et d'aménagement du territoire. Elle permettra également une estimation fiable des rendements agricoles, fournissant ainsi une base solide pour des politiques agricoles plus efficaces et durables.

1.4 Structure du rapport

Après avoir présenté dans le chapitre 1 le contexte, la problématique et la motivation de ce travail. Le chapitre 2 présente un panorama des méthodes de l'état de l'art pour l'analyse d'images basée sur l'intelligence artificielle, en mettant l'accent sur les méthodes supervisées et non supervisées et nous plongerons dans les détails des modèles d'apprentissage profond, les techniques d'entraînement et les fonctions d'activation. Ensuite, dans le chapitre 3, nous explorerons en détail quelques méthodes que nous avons choisies pour la génération de carte d'occupation du sol, en analysant les avantages et les inconvénients de chacune d'elles. Le chapitre 4 se concentre sur le développement d'une application web dédiée à la visualisation des résultats obtenus. Enfin, le chapitre 5 dresse un bilan des travaux effectués et nous traçons les perspectives de recherche envisagées.

Chapitre 2

Analyse de Séries Temporelles d'Images Satellites (STIS)

2.1 Méthode d'analyse des STIS

La génération automatique de cartes d'occupation des sols à partir d'images satellite repose essentiellement sur des méthodes de classification. L'objectif fondamental de ces méthodes est de développer un modèle capable d'assigner à chaque pixel temporel de la STIS une catégorie spécifique (par exemple, eau, forêt, culture, etc.). Dans ce contexte, deux approches principales sont utilisées : l'apprentissage supervisé et l'apprentissage non supervisé.

Les approches non-supervisées, dites en anglais méthodes de *clustering*, sont conçues pour réaliser un regroupement basé sur des stratégies et critères uniques. La similarité entre les éléments constitue le fondement de la création de *clusters*. Sur cette base, un algorithme doit déterminer si des éléments doivent être regroupés ou séparés [9]. Parmi ces méthodes, nous citons *k-means*, les cartes auto organisées (SOM) ou technologie itérative d'analyse de données auto-organisée (ISODATA). Ces techniques sont particulièrement utilisées en l'absence de données précises sur les types d'occupation des sols. De plus, les méthodes de *clustering* deviennent plus coûteuses à mesure que la taille de l'image augmente, notamment en termes du nombre de pixels et de bandes spectrales. Pour ces raisons, les approches supervisées sont généralement privilégiées dans le contexte de la cartographie sur de grandes étendues [10]. Une étape supplémentaire d'étiquetage des *clusters* est nécessaire pour avoir le résultat final. Contrairement à l'apprentissage non supervisé, l'apprentissage supervisé implique l'utilisation d'ensembles de données pré-étiquetées pour entraîner des algorithmes à classifier les séries temporelles d'images satellitaires (SITS). Ce type d'approches nécessite une expertise humaine pour annoter les données d'entraînement, mais elles permettent de produire des classifications précises et spécifiques aux classes prédéfinies.

Ces deux grandes familles de méthodes, supervisées et non-supervisées, sont utilisées de différentes manières. Les méthodes traditionnelles, telles que la régression linéaire et les arbres de décision, sont largement utilisées pour des tâches de classification et de régression. En revanche, les méthodes basées sur l'apprentissage profond, comme les réseaux de neurones, sont plus adaptées pour capturer des structures complexes dans les données, mais nécessitent souvent plus de données et de puissance de calcul.

2.2 Méthode traditionnelle

Les méthodes de classification non supervisée appliquées aux STIS reposent souvent sur le regroupement des pixels temporels . Par exemple, l'utilisation de la distance Dynamic Time Warping (DTW), elle est une adaptation de la distance de *Levenshtein* qui permet de mesurer la similarité entre deux séquences en prenant en compte les décalages temporels [11]. D'autres approches exploitent des vecteurs de caractéristiques contenant des informations temporelles ainsi que des données spatiales, telles que les tailles des régions ou les indices de texture. Certaines stratégies consistent à réduire d'abord la dimensionnalité des données en utilisant des modèles stochastiques avant d'appliquer le regroupement, tandis que d'autres appliquent le regroupement directement [12, 13]. Une approche différente, fondée sur les objets, consiste à appliquer le regroupement sur des séquences temporelles, ce qui aboutit à une représentation sous forme de graphes [14].

Les techniques de classification supervisée sont largement employées dans le domaine des images satellite à haute résolution (STIS). Parmi ces méthodes, on retrouve l'utilisation des *Forêts aléatoires* [15] pour la cartographie de l'occupation des sols, ainsi que les *SVM* ou les *k* plus proches voisins, noté *k-NN* comme *k Nearest Neighbours*.

Dans cette familles de méthodes, une étape d'extraction de caractéristiques est indispensable afin d'enrichir les données brutes d'informations supplémentaires. Ces caractéristiques permettent de transformer l'information visuelle brute en une forme plus compacte et exploitable pour diverses applications. Les méthodes d'extraction de caractéristiques sont nombreuses. Cependant, plusieurs familles d'extraction de caractéristiques se distinguent selon leur niveau d'extraction. Nous distinguons ici les caractéristiques colorimétriques, spatiales, temporelles et les caractéristiques spatio-temporelles.

2.2.1 Caractéristiques colorimétriques

Les images satellitaires sont constituées de plusieurs bandes spectrales. Dans cette partie, nous nous focalisons que sur le satellite Sentinel-2. Ce dernier offre des images avec 13 bandes spectrales. Les bandes spectrales situées dans le visible et le proche-infrarouge (bandes 2, 3, 4, et 8) ont une résolution de 10 mètres. Tandis que les bandes dans le spectre rouge-bordure (bandes 5, 6, 7, et 8A) et certaines bandes dans le court-

infrarouge (bandes 11 et 12) possèdent une résolution de 20 mètres, tandis que les bandes du bleu côtier (bande 1) et les bandes dédiées à la cartographie des aérosols et de la vapeur d'eau (bandes 9 et 10) offrent une résolution de 60 mètres. Le tableau 2.1 présente les noms des bandes spectrales en fonction de leurs indices.

Bandes spectrales	Nom de la bande	Résolution spatiale
B1	AÉROSOL CÔTIER	60
B2	Bleu (B)	10
B3	Vert (V)	10
B4	Rouge (R)	10
B5	Red edge 1	20
B6	Red edge 2	20
B7	Red edge 3	20
B8	Proche-infrarouge (Pir)	10
B8A	Pir étroit	20
B9	Vapeur d'eau	60
B10	Infrarouge court cirrus	60
B11	Infrarouge court 1	20
B12	Infrarouge court 2	20

TABLEAU 2.1 – Définissements de bandes spectrales de Sentinel-2.

Cependant, pour les classes complexes, ces bandes ne fournissent pas une information suffisamment distinctive pour une bonne classification. Dans la littérature spécialisée en télédétection, on trouve des mentions d'attributs qui peuvent être dérivés des différentes bandes spectrales de l'image. Ces attributs peuvent prendre diverses formes : radiométriques, texturales ou géométriques. Dans le domaine de la télédétection, la combinaison des bandes spectrales permet d'extraire des informations spécifiques sur des objets tels que la végétation, l'eau ou les bâtiments. Un exemple notable est l'indice de végétation normalisée (NDVI), calculé à partir des bandes spectrales PIR et R [16, 17]. Sa formule de calcul 2.1

$$NDVI = \frac{Pir - R}{Pir + R} \quad (2.1)$$

Comme la végétation, les zones hydriques ont aussi leur indice nommé Normalized Divsied Water Index (NDWI). Ce dernier est calculé avec les bandes spectrales V et Pir [18]. La Formule 2.2 associée à cet indice est la suivante :

$$NDWI = \frac{V - Pir}{V + Pir} \quad (2.2)$$

Un autre indice spécifique aux sols nus, il s'appelle indice de brillance (IB). Ce dernier permet de distinguer entre les zones végétalisées et les sols nus. Il se calcule avec les bandes spectrales R et Pir via la Formule 2.3

$$IB = \sqrt{R^2 + Pir^2} \quad (2.3)$$

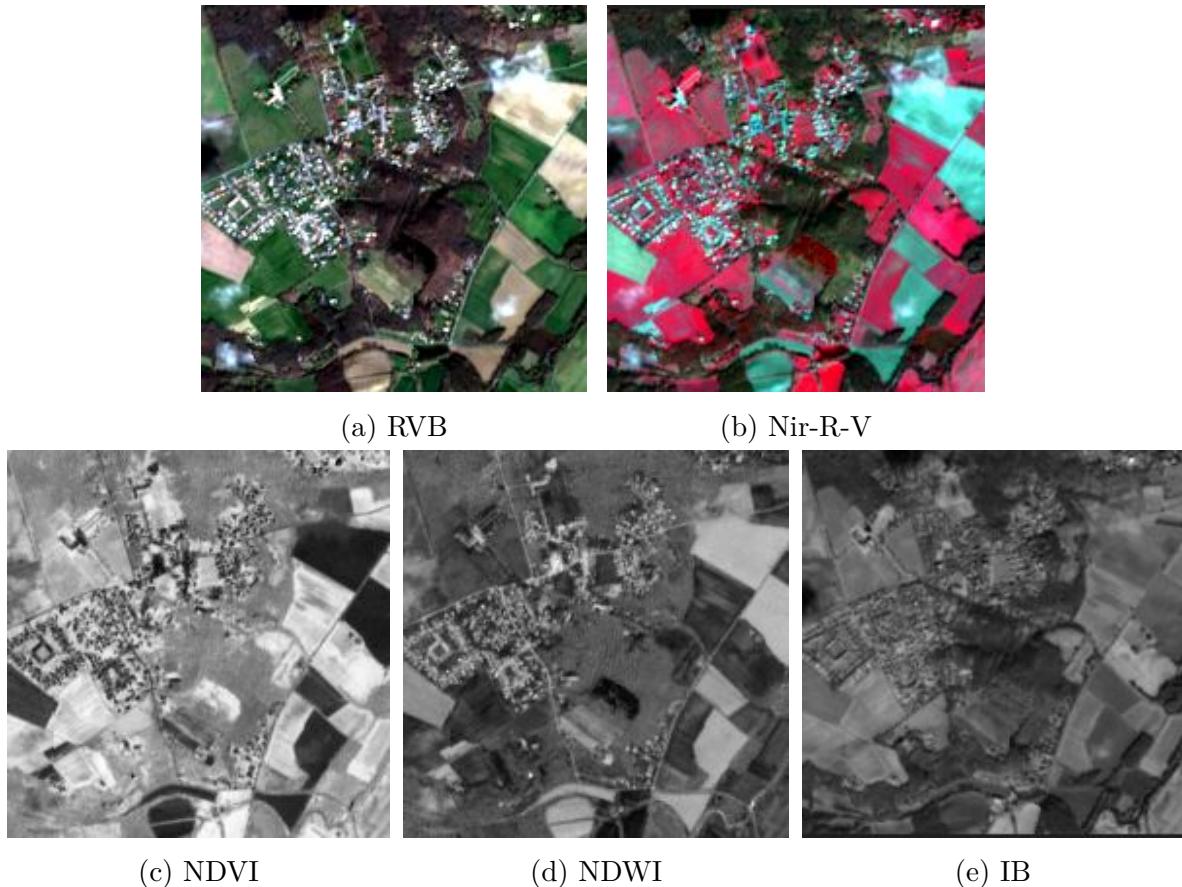


FIGURE 2.1 – Illustration d'une image Sentinel-2 avec différentes configurations des bandes spectrales et des différents indices de télédétection.

La figure 2.1 présente une image Sentinel-2 sous différentes configurations. Les sous-figures 2.1.(a, b) montrent deux manières de visualiser cette image. La première configuration utilise les bandes spectrales visibles, à savoir le rouge, le vert et le bleu, permettant ainsi de voir l'image dans des couleurs naturelles, similaires à celles perçues par l'œil humain. Par exemple, la végétation apparaît en vert ou en jaune selon la saison. En revanche, la deuxième configuration repose sur les bandes du proche-infrarouge, du rouge et du vert. Dans ce cas, la végétation apparaît en rouge au lieu de vert, ce qui est particulièrement utile pour les géographes car cela facilite la distinction entre les différentes occupations du sol. Les sous-figures 2.1.(c, d, e) illustrent trois indices de télédétection : le NDVI, le NDWI et l'IB, calculés selon leurs formules respectives. Le

NDVI met en évidence les zones agricoles à forte végétation, tandis que le NDWI fait ressortir les zones hydratées ou les étendues d'eau. L'indice IB fournit des informations supplémentaires sur la qualité du sol.

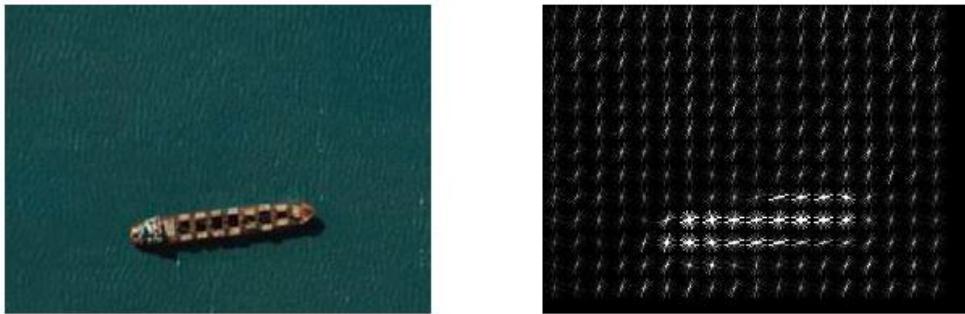
2.2.2 Caractéristiques spatiales ou de textures

Parmi les méthodes les plus influentes et robustes développées au cours des dernières décennies, nous trouvons la Transformation de Caractéristiques Invariantes d'Échelle (SIFT), l'Histogramme des Gradients Orientés (HOG) et les Modèles Binaires Locaux (LBP). Chacune de ces caractéristiques a été utilisée dans plusieurs cas d'applications dont la télédétection. Les caractéristiques SIFT, introduit par Lowe en 1999 [19], identifie des points clés dans une image qui sont invariants à l'échelle et à la rotation, ce qui le rend approprié pour la correspondance de caractéristiques entre différentes images dans une série temporelle. Les SIFT ont été utilisé dans le cadre de la télédétection pour faire la reconnaissance d'objets [20] et aussi pour faire la classification du sols [21]. Les HOG, proposé par Dalal et Triggs en 2005 [22], capture la distribution des gradients dans les régions d'image locales, permettant la détection des formes et des structures d'objets. Ce dernier a été utilisé pour la détection de bateaux dans les océans [23]. Les LBP, introduit par Ojala et al. en 1996 [24], décrit les motifs de texture dans les voisinages locaux des pixels de l'image, fournissant des caractéristiques discriminantes pour l'analyse basée sur la texture. En télédétection les LPB ont été utilisés pour la détection de changement [25]. Il y a aussi les caractéristiques statistiques de texture fournissent des informations sur la distribution globale des valeurs de niveau de gris dans une image. Les textures de Haralick proposées par Haralick et al. en 1973 [26], quant à elles, sont basées sur la matrice de co-occurrence des niveaux de gris (GLCM). Ensuite différentes métriques sont calculés afin d'avoir des informations statistiques représentant les caractéristiques de textures. Ces métriques sont représentées dans le tableau 2.2.

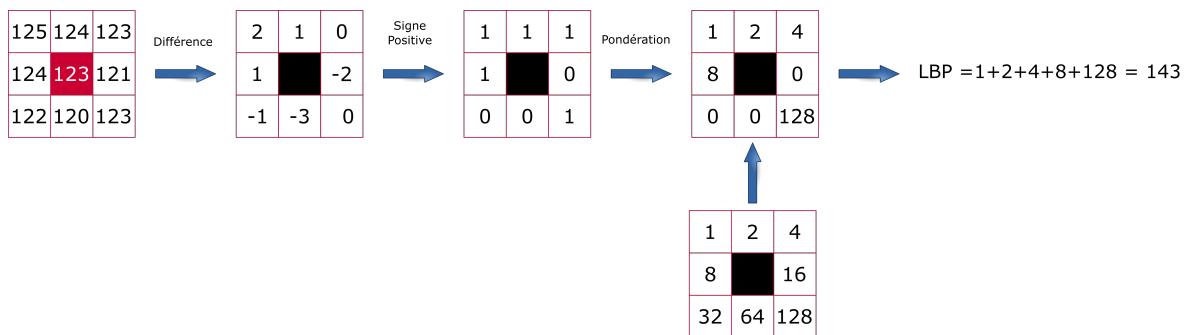
TABLEAU 2.2 – Mesures de textures basées sur GLCM.

Métrique	Formule
ASM	$\sum_{i,j=1}^L p^2(i,j)$
Énergie	\sqrt{ASM}
Entropie	$\sum_{i,j=1}^L p(i,j) \times \log(p(i,j))$
Contrats	$\sum_{i,j=1}^L p(i,j) \times (i - j)$
Homogénéité	$\sum_{i,j=1}^L \frac{p(i,j)}{1+(i-j)^2}$
Dissimilarité	$\sum_{i,j=1}^L p(i,j) \times i - j $
Corrélation	$\sum_{i,j=1}^L \left[\frac{(i-\mu_i) \times (j-\mu_j)}{\sqrt{\sigma_i^2 \times \sigma_j^2}} \right]$

La figure 2.2 illustre deux exemples de caractéristiques. Dans l'illustration 2.2.a,



(a) Résultat visuel des HOG pour la détection de bateau [23].



(b) Génération du code LBP d'un pixel.

FIGURE 2.2 – Illustration de deux exemples de caractéristiques. (a) viualisation des HOG pour la détection de bateaux ; (b) Schéma de génération d'un code LBP pour un pixel.

une visualisation des HOG sur une image d'un bateau dans l'océan. Nous remarquons que le gradient dans la mère est plutôt stable par rapport à celui du bateau. Cela permet de faire la détection de celui-ci. Dans l'illustration 2.2.b, un schéma explicatif du calcul des LBP est présenté.

2.2.3 Caractéristiques temporelles

Le domaine temporel joue un rôle important dans l'analyse des séries temporelles. Certaines méthodes sont conçues pour ne traiter que ce domaine. Ces méthodes sont plusieurs et peuvent être des méthodes de réduction de dimension, d'extraction de caractéristiques artisanales ou même d'apprentissage machine. Chacune de ces caractéristiques a été utilisée dans plusieurs cas d'applications, notamment dans le domaine de la télédétection.

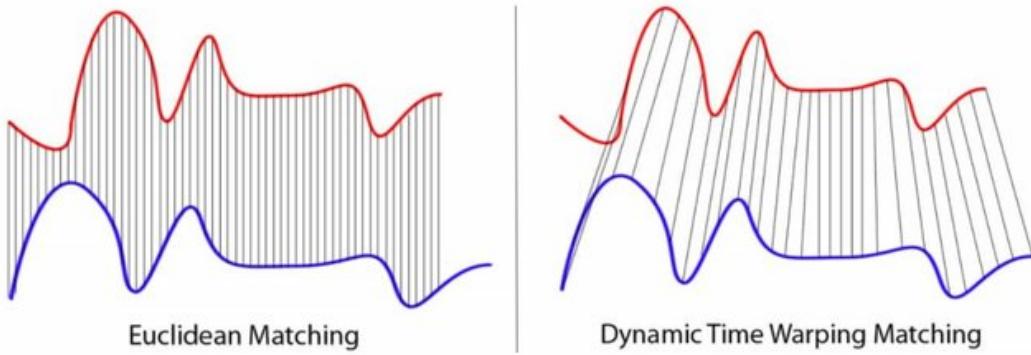
Certaine méthode d'apprentissage machine, comme les k plus proches voisins, a été utilisé directement pour distinguer les séries temporelles, mais pas avec la distance euclidienne. Une nouvelle métrique est utilisé qui permet de faire l'alignement entre deux

séries temporelles. Cette distance s'appelle la *Dynamic Time Warping* (DTW). La figure 2.3.a illustre la comparaison de la distance Euclidienne et la DTW. Les méthodes de réduction de dimension sont plusieurs, le plus utilisé est l'Analyse en Composantes Principales (PCA) qui est une méthode statistique qui compresse les données tout en conservant le plus d'information possible. Elle transforme les données d'origine en un nouvel ensemble de variables non corrélées appelées composantes principales. Les premières composantes principales capturent la majorité de la variance des données [27]. Parmis les méthodes d'extraction de caractéristiques artisanales, une adaptation des Scale-Invariant Feature Transform (SIFT) appliquée sur le domaine temporel. SIFT sont des caractéristiques qui décrivent des points d'intérêt locaux dans des images. La SIFT temporelle se réfère à l'application de la SIFT sur des séries temporelles d'images pour suivre les points d'intérêt au fil du temps, permettant ainsi de capturer les changements dynamiques dans les images satellitaires [20, 28]. Une autre caractéristique artisanale permettant de mesurer la stabilité temporelle des SITS. Cette dernière se réfère à la constance des caractéristiques d'une région spécifique dans une série d'images au fil du temps. Pour les images satellitaires, cela signifie que certaines caractéristiques du sol restent inchangées pendant une certaine période, ce qui peut être utilisé pour identifier des zones stables et distinguer des changements significatifs [29]. Une telle caractéristique a été définie par l'utilisation d'un algorithme de compression nommé *Run Length Encoding* (RLE) et ensuite extraire la valeur maximum du code compressé [30]. La figure 2.3.b illustre le résultat du RLE sur un exemple d'un pixel temporel. L'intelligence artificielle (IA) symbolique est une approche de l'IA qui utilise des symboles et des règles explicites pour représenter la connaissance et le raisonnement. Contrairement à l'apprentissage automatique, qui repose sur des données et des modèles statistiques, l'IA symbolique se base sur la manipulation de symboles pour effectuer des tâches cognitives [31]. Les Modèles de Markov Cachés (Hidden Markov Models - HMM) sont des modèles statistiques utilisés pour représenter des systèmes où l'état observé est influencé par des états cachés non directement observables. Dans le contexte des images satellitaires, les HMM peuvent être utilisés pour modéliser les transitions entre différents types de couverture du sol au fil du temps [32].

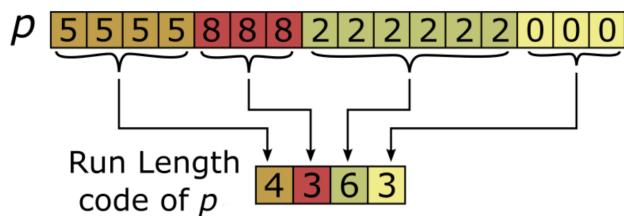
Caractéristiques spatio-temporelles

L'analyse conjointe des domaines spatial et temporel permet l'extraction de caractéristiques spatio-temporelles qui fournissent une vision plus complète des changements dans les séquences d'images. Nous trouvons les caractéristiques spatio-temporelles telles que HOG3D (Histogram of Oriented Gradients 3D), les Trajectoires Denses, 3D Scale-Invariant Feature Transform (3D-SIFT), Extended Speeded-Up Robust Features (eSURF) et les Local Trinary Patterns (LTP). Nous détaillons par la suite ces méthodes et citons leurs cas d'applications pour l'analyse de séquence d'images.

Les caractéristiques HOG3D est une extension de la méthode HOG classique, utilisée pour la reconnaissance d'objets dans les images. HOG3D ajoute une dimension temporelle, permettant de capturer les variations spatiales et temporelles des gradients



(a) Différence entre la distance Euclidienne et la DTW.

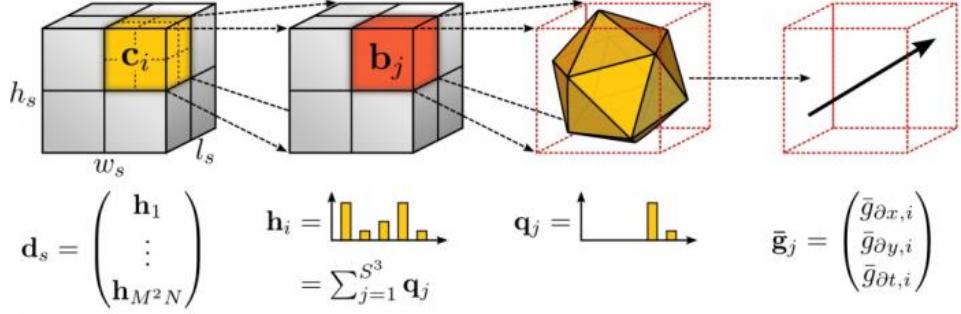


(b) Application du RLE sur une série temporelle [30].

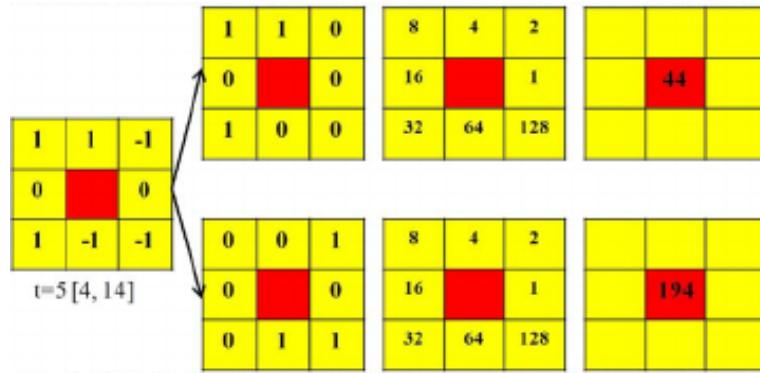
FIGURE 2.3 – Illustration de la DTW et la mesure de stabilité.

dans une séquence d’images. Cette méthode est particulièrement utile pour analyser les vidéos et les séquences d’images, comme celles obtenues par les satellites [35]. Ce dernier a été utilisé pour la détection et la classification des véhicules individuels et des piétons dans les scènes urbaines [36]. La figure 2.4.a, illustre la représentation des différentes étapes de construction du(descripteur HOG3D. Les Trajectoires Denses sont une méthode pour extraire des caractéristiques spatio-temporelles à partir de vidéos en suivant les trajectoires de points d’intérêt denses sur une séquence d’images. Contrairement aux approches basées sur des points d’intérêt clairsemés, cette méthode suit un grand nombre de points, ce qui permet de capturer des informations plus riches sur les mouvements dans la vidéo. Dans le contexte des images satellitaires, les Trajectoires Denses ont été utilisées pour analyser les changements de la couverture du sol et détecter des événements dynamiques comme les mouvements de masses d’eau ou de nuages [37]. 3D-SIFT est une extension de la méthode SIFT utilisée pour la détection et la description de points d’intérêt locaux dans les images. Cette caractéristique est appliquée sur des volumes tridimensionnels, permettant ainsi de capturer les variations spatiales et temporelles dans une séquence d’images.

Cette technique est particulièrement utile pour l’analyse des vidéos, car elle permet de suivre les points d’intérêt à travers le temps et de détecter les changements dynamiques dans la couverture du sol [35]. Les eSURF est une extension de la méthode SURF (Speeded-Up Robust Features) utilisée pour la détection et la description de



(a) Aperçu du descripteur HOG3D [33].



(b) Calcul de l'opérateur LTP [34].

FIGURE 2.4 – Illustration de deux exemples de caractéristiques.(a) Aperçu du descripteur HOG3D , (b) Calcul de l'opérateur LTP.

points d'intérêt dans les images. Elle améliore la robustesse de SURF en ajoutant des caractéristiques supplémentaires, telles que des descripteurs plus longs et une meilleure invariance aux transformations. Dans le contexte des images satellitaires, eSURF a été utilisé pour détecter des points d'intérêt à travers différentes dates et conditions d'observation, facilitant ainsi le suivi et l'analyse des changements de la couverture du sol au fil du temps [38]. Les Local Trinary Patterns (LTP) sont une extension des Local Binary Patterns (LBP), qui sont couramment utilisés pour la reconnaissance de textures. LTP divise les pixels en trois catégories (moins que, égal à, ou plus grand que le pixel central) au lieu de deux, comme dans LBP. Cette méthode rend LTP plus robuste aux variations d'éclairage et de bruit. Dans le contexte des images satellitaires, LTP peut être utilisé pour extraire des informations texturales spatio-temporelles qui aident à détecter et analyser les changements de la couverture du sol à travers le temps [39]. La figure 2.4.b, illustre le calcul de l'opérateur LTP.

L'utilisation de ces caractéristiques artisanales dans l'analyse de séries temporelles d'images satellites a montré des résultats prometteurs. Ces méthodes de caractérisation manuelle ont été efficacement mises en œuvre pour l'examen des STIS, en tenant compte les dimensions spatiales et temporelles [40].

2.3 Méthode basées sur l'apprentissage profond

Récemment, les méthodes de l'apprentissage profond basées sur les réseaux de neurones profonds ont été considérés pour la classification des séries temporelles. Ces méthodes sont regroupées dans deux grandes familles : les réseaux de neurones récurrents et les réseaux de neurones convolutifs, on appliquons respectivement les abréviations anglaises de ces deux familles, *RNN* comme *Recurrent Neural Network* et *CNN* comme *Convolutional Neural Network*.

Les *RNN* ont été conçus pour traiter les données séquentielles comme les séries temporelles. Ces modèles sont dotés d'une mémoire qui leur permet de traiter des séquences de longueurs différentes [41], mais ils rencontrent certains problèmes et limite lors de l'apprentissage. Afin de contrer ces problèmes, deux modèles sont proposés. Le premier est le *Gated Recurrent Unit (GRU)* et le deuxième est le *Long Short-Term Memory (LSTM)*. La figure 2.5 illustre les trois modèles de réseaux de neurones récurrents. Le modèle *RNN* est le plus simple comporte une seule boucle de rétroaction connecter à lui-même, on peut voir la flèche qui relie la sortie (h_t) à l'entrée (x_t), ce qui représente la rétroaction temporelle. Le modèle *LSTM* se constitue en trois portes : la porte d'entrée (*Input gate*), la porte de sortie (*Output gate*) et la porte d'oubli (*Forget gate*). Chaque porte effectue des opérations spécifiques pour la gestion de l'information à court et long terme. Le modèle *GRU* combine la porte d'entrée et la porte d'oubli en une seule porte appelée porte de mise à jour (*Update gate*) et inclut également une porte de ré-initialisation (*Reset gate*). C'est comme une version simplifiée du *LSTM*.

Le modèle *LSTM* (Long Short-Term Memory) est particulièrement populaire. La force des réseaux récurrents réside dans leur capacité à retenir des informations à travers de longues séquences de données, ce qui les rend idéaux pour le traitement séquentiel. Ces types de modèles ont été appliqués avec succès à diverses tâches, telles que la reconnaissance vocale [42], la détection des émotions [43], et la cartographie de

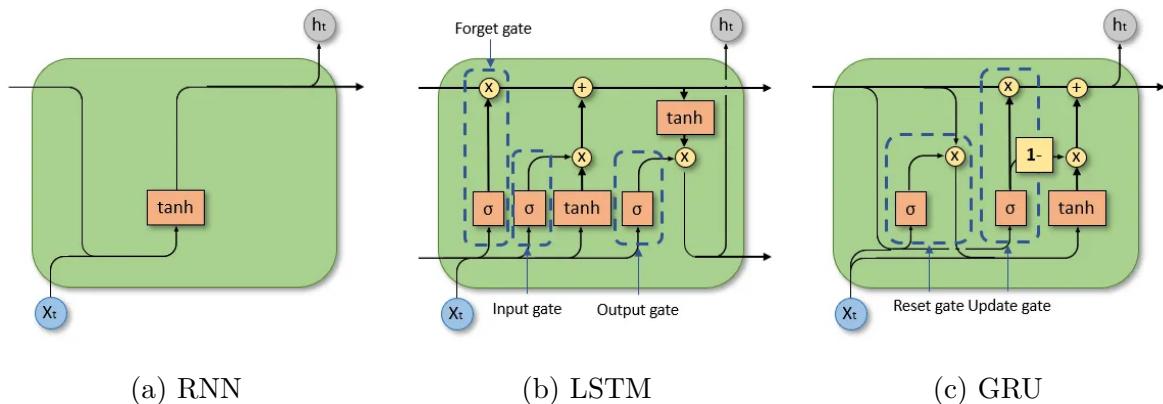


FIGURE 2.5 – Illustrations de l'architecture *RNN*, *LSTM* et *GRU*.

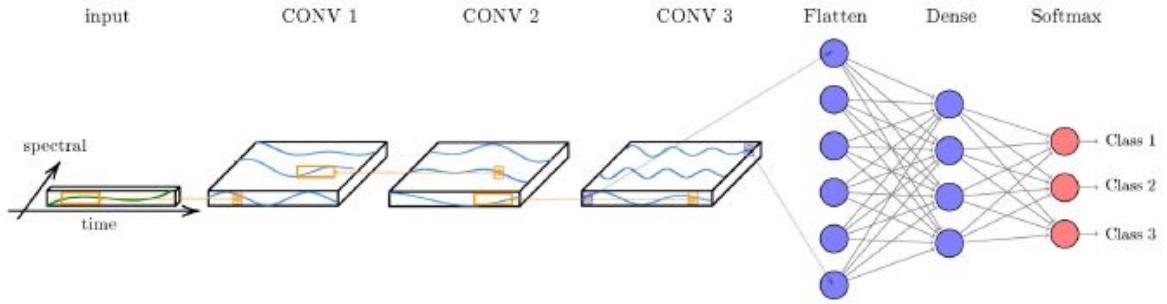


FIGURE 2.6 – Illustration de *TempCNN* (figure reprise de [1]).

l’occupation des sols dans le domaine de l’observation de la Terre [44, 45]. Leur capacité à modéliser les dépendances temporelles permet d’améliorer les performances dans ces domaines complexes.

Au départ, les *CNN* ont été conçus pour analyser des images *2D* et les convolutions ne s’appliquaient que sur le domaine spatial [46]. Ce type de modèles sont aussi dotés d’autres couches telles que *batch normalization* et *dropout*. La couche *batch normalization* à pour but d’accélérer l’entraînement du modèle. Quant à la *dropout*, celle-ci est conçue pour éviter le sur-apprentissage. Une fonction d’activation peut être appliquée après une certaine couche afin que ne sélectionner que les caractéristiques essentielles. Au fil du temps, elles ont été adaptées aux séries temporelles. Par exemple, l’architecture *TempCNN* a été proposée pour la classification des *STIS* [1] en utilisant des convolutions *1D* appliquées dans le domaine temporel. D’autres architectures de *CNN* *2D*, tels que *ResNet*, ont aussi été adapté pour ne traiter que le domaine temporel. Les résultats des expérimentations testé sur la base de donnée proposée par *University of California*¹ démontre le succès d’une telle adaptation [47]. Certaines études montrent que les méthodes par réseaux de neurones profonds permettent d’avoir de meilleurs résultats en termes de classification des séries temporelles que les approches classiques, telles que les forêts aléatoires [47]. Cela est dû aux caractéristiques extraites qui sont optimisées pour la tâche ciblée.

La figure 2.6 illustre l’architecture de TempCNN. Ce dernier prend en entrer un pixel temporel qui peut être univarié ou multivarié qui sera lui propagé à travers les couches du modèle. TempCNN est composée de deux parties. La première consiste à apprendre l’extraction de caractéristiques. Tandis que la deuxième vise à prendre une décision. La première partie est dotée de trois blocs. Chaque bloc se constitue d’une couche de convolution, une couche de *batch normalization*, une couche qui applique une fonction d’activation et une couche de *dropout*. La deuxième partie commence par aplatisir les données. Ensuite, une couche linéaire suivie par une *Softmax* sont appliquées afin d’avoir une décision.

Une autre stratégie consiste à encoder les séries temporelles en des représentations

1. <https://timeseriesclassification.com/dataset.php>

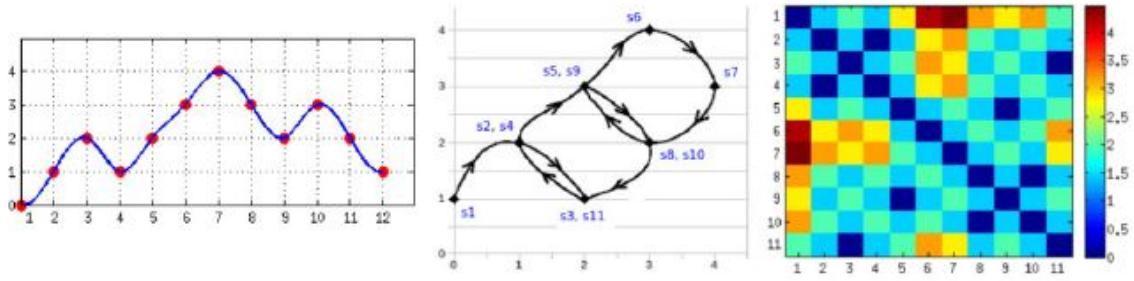


FIGURE 2.7 – Transformation d’une séquence temporelle en une matrice de *RP*. (Gauche) la séquence temporelle de longueur 12. (Milieu) plan 2D de l’espace des trajectoires. (Droite) la matrice résultante de *RP* de taille 11×11 [2].

2D. Cela permet l’utilisation des *CNN* classiques 2D pour la classification de ces représentations 2D et aussi bénéficie des modèles pré-entraînés sur de grande base de donnée tel que *ImageNet*. Parmi ces méthodes, nous citons les Récurrence Plots (*RP*) [48] qui sont des représentations 2D permettant d’explorer les récurrences des trajectoires de chaque point dans l’espace des phases. Dans la théorie des systèmes dynamiques, l’espace des phases représente tous les états possibles d’un système. Soit le pixel temporel $p = (p_t)_{t=1}^T$ où T est la longueur de p . Les trajectoires pour chaque point de la série sont $\vec{p} = (\vec{p}_1 : (p_1, p_2), \dots, \vec{p}_{T-1} : (\vec{p}_{T-1}, \vec{p}_T))$ avec $T-1$ états. La génération de la matrice des *RP* est faite par le calcul de la distance entre tous les états des trajectoires comme indiqué dans l’équation 2.4 :

$$RP(i, j) = \begin{cases} 1, & \text{si } \|\vec{p}_i - \vec{p}_j\| \leq \varepsilon \\ 0, & \text{sinon} \end{cases} \quad \text{avec } i, j \in ([1, 1 - T])^2 \quad (2.4)$$

La figure 2.7 illustre les étapes de la transformation d’une séquence temporelle en une matrice de *RP*. Le seuil ε peut être calculé de deux manières différentes. La première façon est basée sur la mesure de la densité des points selon un pourcentage. La deuxième façon est aussi basée sur un pourcentage mais avec la distance maximale entre les points. Le choix du calcul du seuil ε dépend fortement de la nature des séquences étudiées.

Une autre méthode qui permet d’avoir une représentation 2D de la corrélation temporelle entre les points d’une séquence est la *Gramian Angular Field* [49]. La première étape de cette méthode consiste à normaliser les données entre $[-1, 1]$. Ensuite les coordonnées polaires, qui sont le rayon r et l’angle θ , sont calculées pour chaque point du pixel temporel. Puis deux types de corrélations temporelles entre les points peuvent être extraites. La première est le cosinus de la somme des angles qui est la *Gramian Angular Summation Field (GASF)* et la deuxième est le sinus de la différence des angles qui est la *Gramian Angular Difference Field (GADF)*. L’équation 2.5 présente respectivement

les deux formules pour calculer la *GASF* et la *GADF* :

$$\begin{aligned} GASF(i, j) &= \cos(\theta_i + \theta_j), \quad \forall i, j \in [1, T] \\ GADF(i, j) &= \sin(\theta_i - \theta_j), \quad \forall i, j \in [1, T] \end{aligned} \quad (2.5)$$

Enfin, il existe les méthodes qui utilisent la transformée de Fourier à temps court, dite en anglais *Short Time Fourier Transform (STFT)*, pour générer plusieurs spectres avec différentes fréquences conduisant à créer un spectrogramme [50]. La figure 2.8 illustre les résultats visuels des *RP* non binarisés, *GASF*, *GADF* et *STFT* sur deux séries temporelles issues de la base GunPoint. Ces stratégies permettent de bénéficier des avantages des *CNN 2D* qui peuvent déjà être entraînés à diverses tâches de vision par ordinateur, par exemple la classification d'images naturelles où le modèle est entraîné sur la base *ImageNet* [51] qui contient des millions d'exemples et ce dans 1000 catégories différentes.

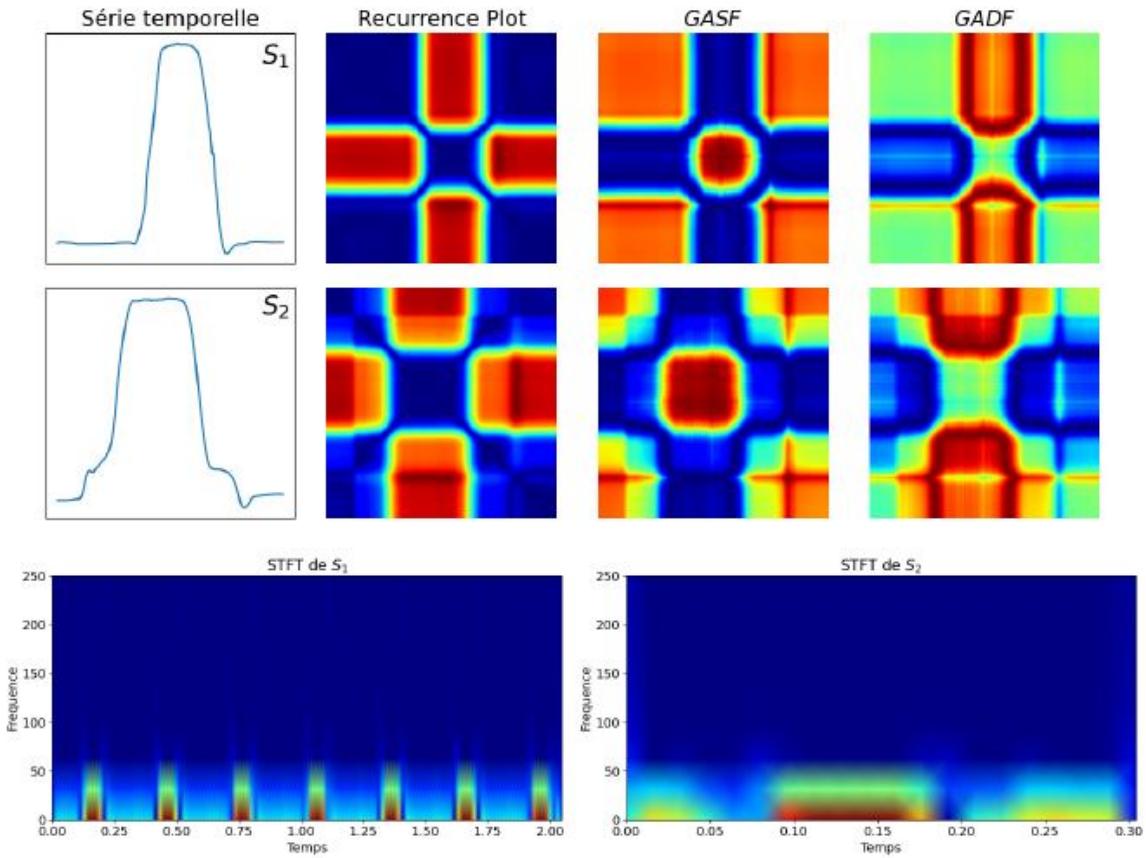


FIGURE 2.8 – Illustration des résultats visuels des *RP*, *GASF*, *GADF* et *STFT* sur deux séries temporelles issues de la base *GunPoint*.

2.4 Synthèse

Nous avons présenté dans ce chapitre un panorama de méthodes de l'état de l'art conçu pour l'analyse des séries temporelles d'images satellitaires, notamment les séries temporelles. Ces méthodes sont divisées en deux familles, les méthodes qui se basent sur l'analyse des séries brute, mais aussi une phase d'enrichissement des séries temporelles avec des caractéristiques artisanales. La deuxième famille de méthodes sont conçus pour être autonome à apprendre l'extraction de caractéristiques et la prise de décision. Cette famille se base sur l'apprentissage profond.

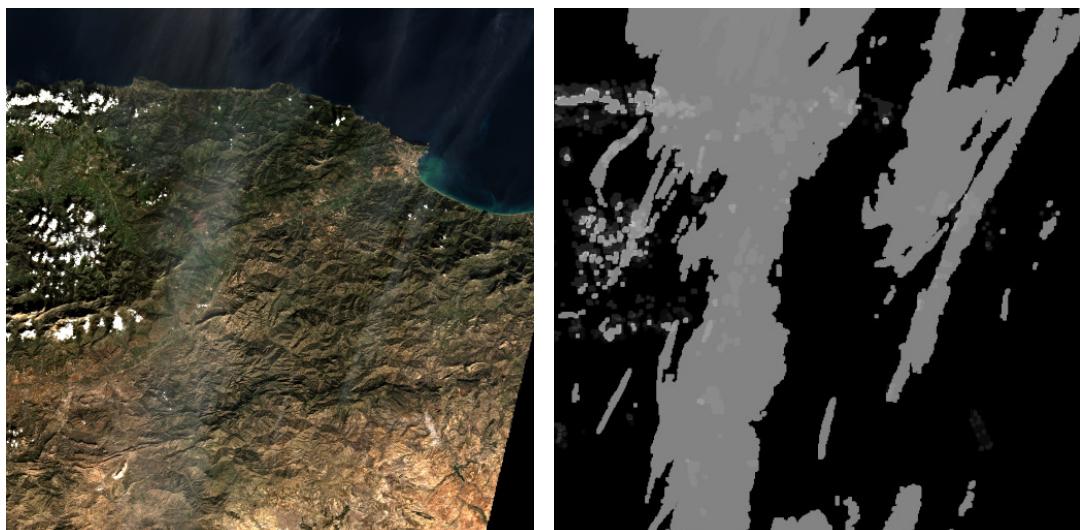
Nous avons constaté que les modèles basés sur l'apprentissage profond donne de meilleurs résultats par rapport aux approches classiques dans la majorité des cas. Dans le chapitre suivant, nous allons faire une étude expérimentale sur des données de télé-détection pour la génération de cartes d'occupation du sol. Dans cette étude, nous allons procéder à une comparaison de différents modèles d'apprentissage machine et d'apprentissage profond.

Chapitre 3

Génération de la carte d'occupation du sol

Nous présentons dans ce chapitre l'étude expérimentale que nous avons menée afin d'évaluer différentes méthodes pour la génération de la couverture des sols afin d'aider les décideurs politiques en matière d'agriculture et d'environnement.

3.1 Définition des STIS



(a) Image Sentinel-2

(b) Masque des nuages

FIGURE 3.1 – Image Sentinel-2 prise le 14/01/2023 avec son masque de nuage.

La constellation de satellites Sentinel-2, lancée par l'ESA, vise à observer la Terre avec une haute fréquence temporelle et spatiale, fournissant ainsi des séries temporelles d'images satellitaires (STIS). Sentinel-2 offre des STIS avec une revisite temporelle de cinq jours, une résolution spectrale de 13 bandes dans le visible et l'infrarouge, ainsi qu'une résolution spatiale allant de 10 à 60 mètres. Ces données offrent une information temporelle cruciale pour analyser de manière approfondie les diverses pratiques de gestion des sols nécessitant un suivi régulier ou saisonnier.

En collaboration avec le CNES/CESBIO et le DLR (The German Aerospace Center), un logiciel appelé MAJA a été développé dans le but d'appliquer les prétraitements nécessaires. Grâce à MAJA, l'ESA partage les STIS de Sentinel-2 corrigées, avec les masques de nuages associés à chacune des images de la série. La figure 3.1 illustre une image Sentinel-2 avec son masque de nuage associé.

Une série temporelle d'images satellitaires (STIS) est un ensemble d'images capturées par un satellite au même endroit mais à des moments différents. Elle est généralement notée $S_{Images} = \langle I_1, \dots, I_N \rangle$, composée de N images de dimensions $W \times H$, où W et H représentent respectivement la largeur et la hauteur de chaque image. Chaque image est composée de plusieurs bandes spectrales qui sont le rouge, le vert, le bleu et le proche infrarouge, ce qui permet de décrire chaque pixel de l'image I^n (avec $n \in [1, N]$) sous la forme de la fonction 3.1. Les notations utilisées sont celles introduites dans l'article [13].

$$I^n : [1, \mathbb{W}] \times [1, \mathbb{H}] \rightarrow \mathbb{Z}^B \\ (x, y) \rightarrow I_1^n(x, y), I_2^n(x, y), \dots, I_B^n(x, y) \quad (3.1)$$

3.2 Présentation des données

Les données utilisées sont deux STIS de Sentinel-2 de l'année 2023. La première STIS couvre la région de Toulouse en France, noté T31TCJ, et la deuxième SITS qui couvre une région du nord-est de l'Algérie, noté T31SFA. Ces notations sont celle des noms des tuiles indexés par le programme d'acquisition des images par le satellite. Les deux STIS, T31TCJ et T31SFA, disposent respectivement de 102 et de 98 images réparties dans l'année. la Figure 3.2 illustre la répartition des images dans l'année de chacune des STIS. Une interpolation linéaire a été appliquée afin de compléter les pixels masqués par les nuages et aussi avoir le même nombre d'images dans les deux STIS. Les bandes spectrales constituant les images sont : le proche-infrarouge (Pir), rouge (R), le vert (V) et le bleu (B).

En complément, nous avons considérés que certaines régions dans les deux STIS. Nous nous sommes focalisés sur la région de la ville de Toulouse sur la tuile T31TCJ, où la taille de la région sélectionnée est de 7200×2000 pixels. Par contre, deux régions sont sélectionnées dans la tuile T31SFA. La première se focalise sur la ville de *Bordj*

Bou Arréridj, de dimensions 2000×2000 pixels et la deuxième sur la ville de *Béjaya* également de dimensions 2000×2000 pixels. Dans ces deux régions, la majorité des pixels couvrent des zones agricoles. La figure 3.4.a illustre la région sélectionnée, sur la tuile T31TCJ, tandis que la figure 3.4.b présente les régions sélectionnées sur la tuile T31SFA."

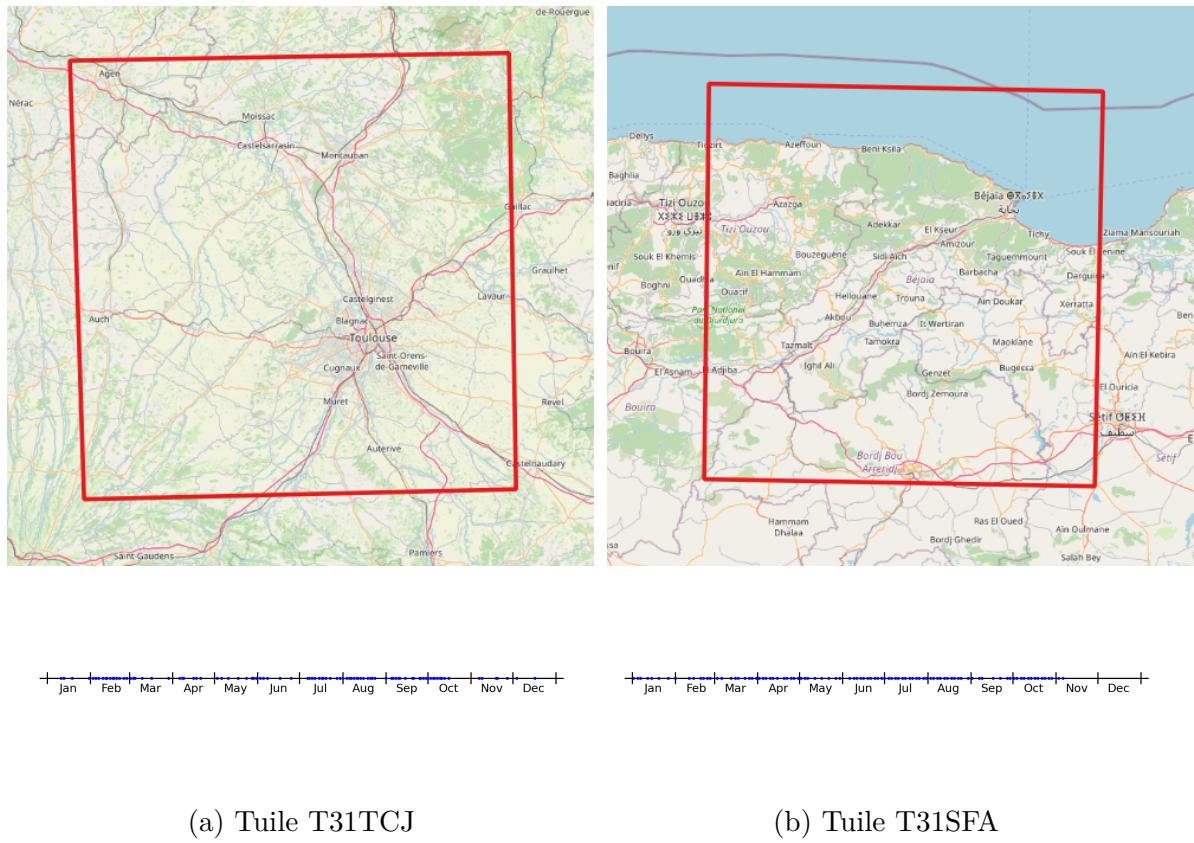


FIGURE 3.2 – Chronologie des acquisitions pour les tuiles T31TCJ et T31SFA de l'année 2023

Concernant la vérité terrain, nous avons utilisé la carte d'occupation du sol de France issue de la chaîne de traitement *iota2* qui est une chaîne de production de cartes d'occupation des sols développée par le *CESBIO (Centre d'Études Spatiales de la BIOSphère)* à partir de données satellitaires, y compris celles de *Sentinel-2*. Cet outil permet de générer des images précises et à haut résolution sur l'utilisation et la couverture des sols. Le point fort de cette donnée est que le résultat de *iota2* a été vérifié et corrigé par des experts géographes tout en indiquant un score de confiance à chaque pixel. La vérité terrain comprend 24 classes différentes. La figure 3.3 présente les classes de la vérité terrain avec leurs codes couleurs. Dans notre cas, certaines classes n'apparaissent pas, car elles ne sont pas disponibles dans la région étudiée.

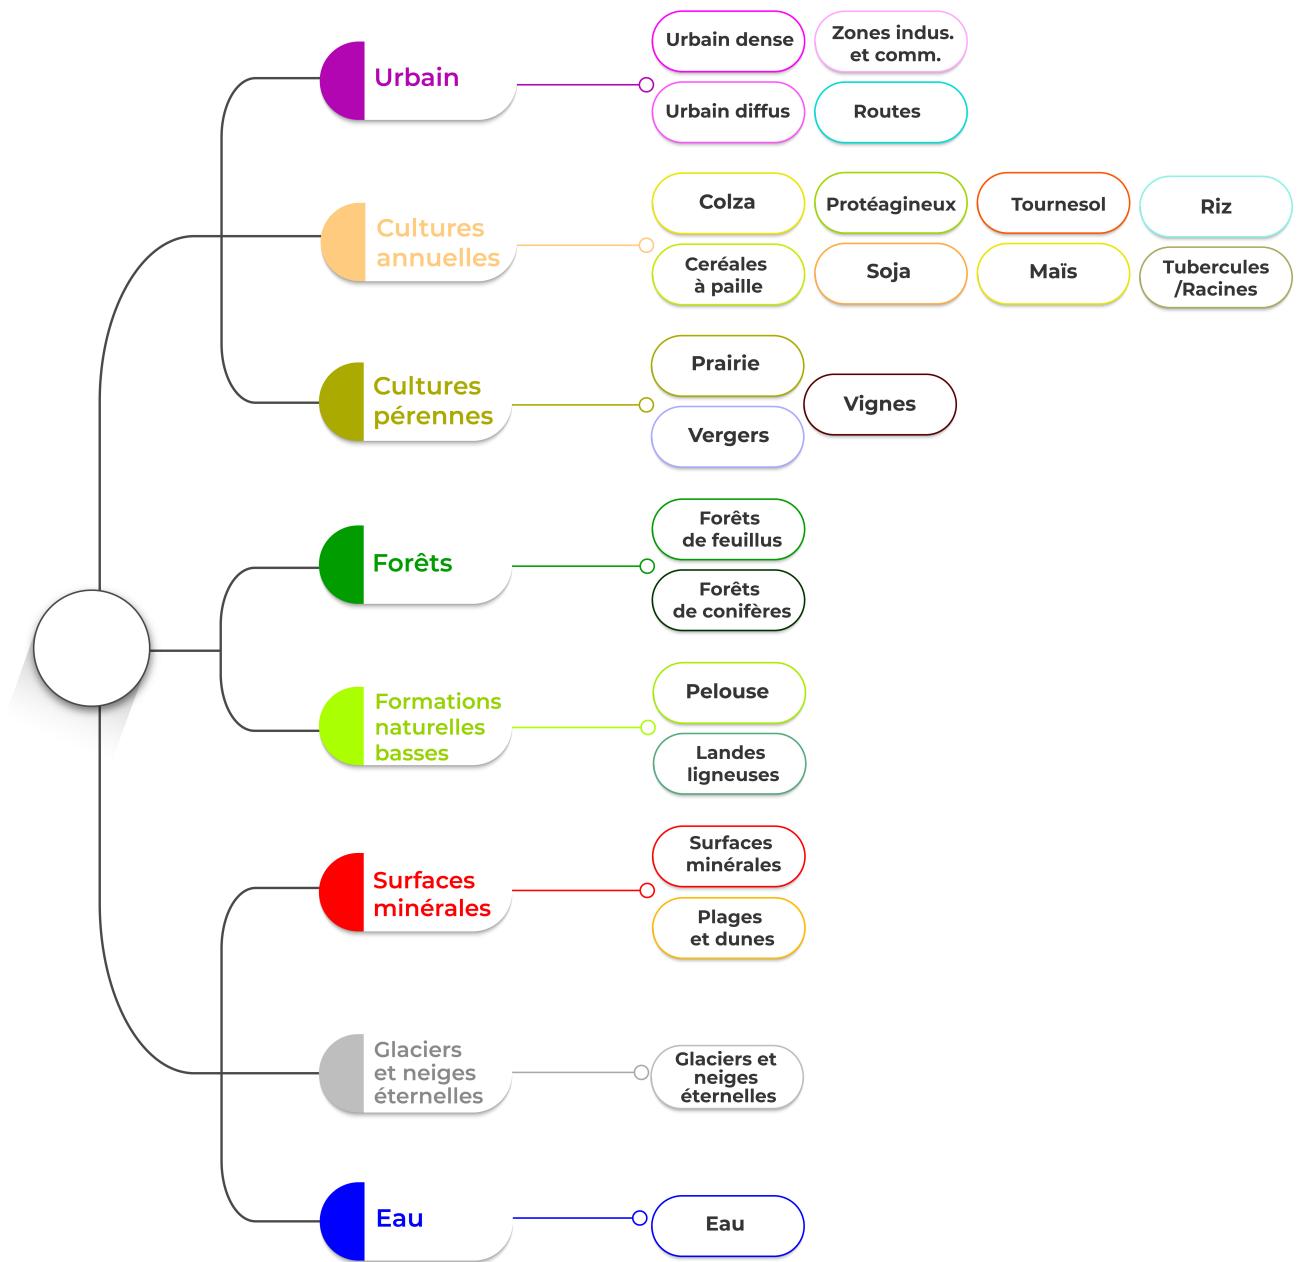
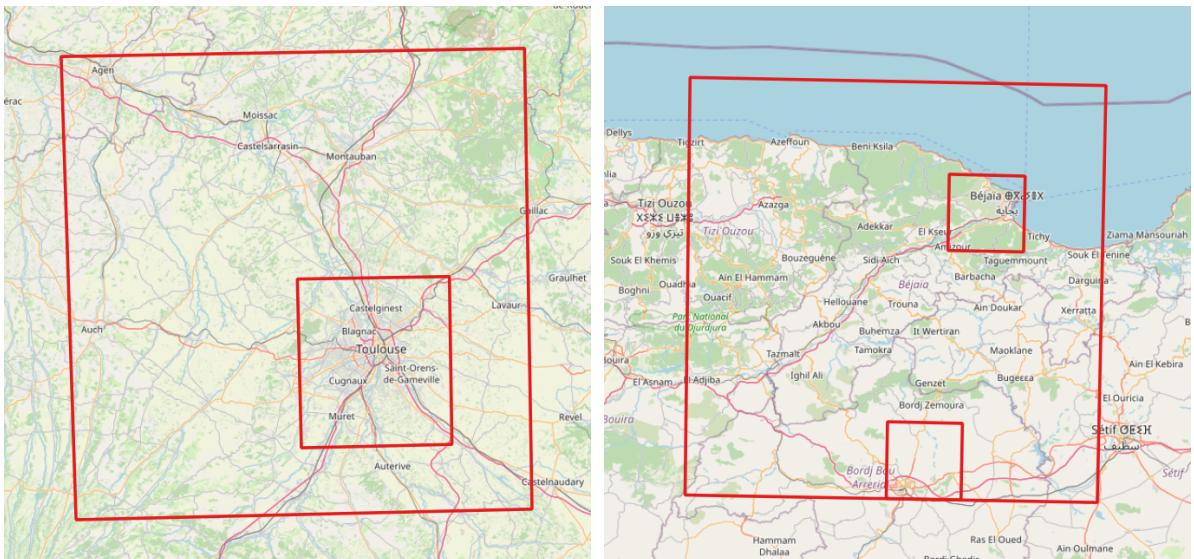


FIGURE 3.3 – Illustration des différents classes de l'ensemble de données d'entraînement



(a) La région de Toulouse, sur la tuile T31TCJ (b) Les régions de Bordj Bou Arreridj et Bejaia, sur la tuile T31SFA.

FIGURE 3.4 – Régions sélectionnées sur les tuiles T31TCJ et T31SFA.

Une fois que la vérité terrain sélectionnée, nous avons divisé la STIS de Toulouse en deux parties. La première va être utilisée pour extraire des données d’entraînement et de validation, tandis que la seconde sera réservée exclusivement à l’inférence et l’évaluation. Les deux régions, Bordj Bou Arréridj et Bejaya, sont utilisés uniquement pour l’inférence afin de générer une carte d’occupation du sol.

3.3 protocole expérimentale

Une fois les données préparées, nous passons à l’étape de l’extraction des pixels temporels à partir des images Sentinel-2. Cette étape essentielle consiste à capturer l’évolution temporelle des propriétés des pixels dans la région d’intérêt.

Pour notre analyse, nous avons sélectionné un million de pixels temporels ayant un score de confiance supérieur à 50% dans la STIS d’entraînement de Toulouse. La figure 3.5 illustre un histogramme pour visualiser la distribution des scores de confiance dans la partie des données d’entraînement. Cette sélection permet de garantir la fiabilité des données utilisées pour l’entraînement des modèles. Les données extraites sont ensuite divisées en deux ensembles : un ensemble d’entraînement et un ensemble de test, disposant respectivement de 80% et de 20% des données initiales. Pour améliorer la fiabilité de nos modèles, nous avons utilisé la technique de validation croisée en cinq plis *5-fold cross-validation*. Cette méthode consiste à diviser l’ensemble d’entraînement en cinq sous-ensembles de taille égale. À chaque itération, un sous-ensemble est utilisé comme ensemble de validation tandis que les quatre autres sous-ensembles sont utilisés pour

l’entraînement. Ce processus est répété cinq fois, chaque sous-ensemble servant une fois de validation. L’utilisation de la validation croisée permet d’évaluer la performance des modèles de manière plus fiable en réduisant la variance due à la partition des données et en fournissant une estimation plus précise de leur capacité de généralisation.

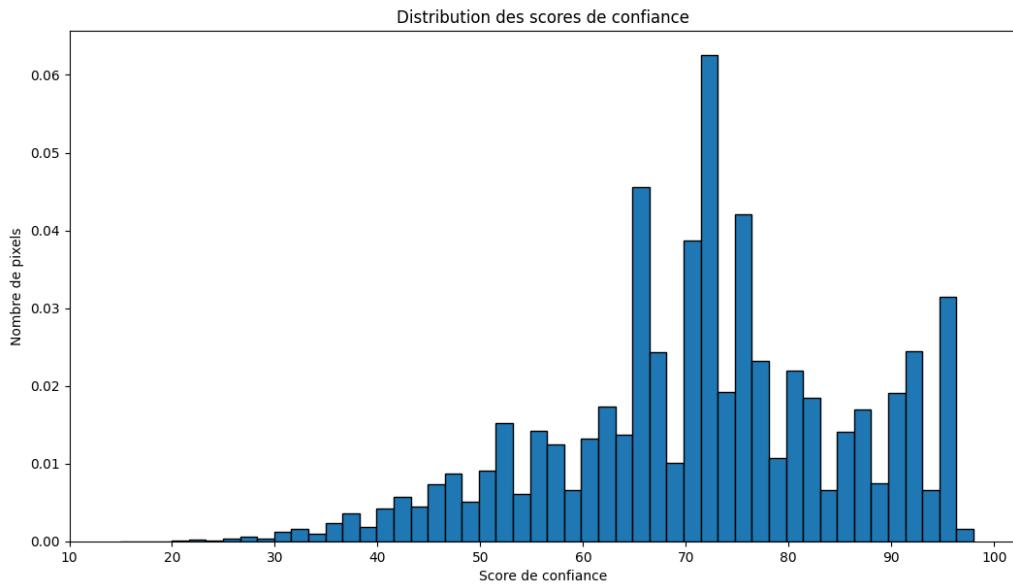


FIGURE 3.5 – Histogramme de la distribution des scores de confiance

L’algorithme des k-plus proches voisins, ou *k-nearest neighbors (KNN)*, est utilisée pour la classification et la régression. Il est basé sur la notion de similarité : pour prédire la classe ou la valeur d’une nouvelle observation, KNN se concentre sur les k observations les plus proches dans l’ensemble d’entraînement. Dans notre application, nous avons utilisé des vecteurs de caractéristiques (pixels) et des étiquettes (labels), avec un nombre de voisins fixé à k=5. Cette méthode est simple à implémenter et peut être très efficace pour des petits ensembles de données. Cependant, KNN peut devenir coûteux en termes de calculs lorsqu'il s'agit de grands ensembles de données, car il doit calculer la distance entre la nouvelle observation et toutes les observations de l’ensemble d’entraînement.

Le modèle *Random Forest (RF)* est un ensemble de plusieurs arbres de décision utilisés pour améliorer la précision et éviter le surapprentissage. Il fonctionne en créant de nombreux arbres de décision lors de l’entraînement et en produisant la classe qui est le mode des classes de chaque arbre individuel. Dans nos expériences, nous avons utilisé des vecteurs de caractéristiques (pixels) et des étiquettes (labels), avec un nombre d’arbres dans la forêt fixé à 20. Le *Random Forest* est puissant et robuste, capable de gérer de grandes quantités de données et de nombreuses variables d’entrée sans risque de surapprentissage. En utilisant plusieurs arbres de décision, il réduit le risque de variance et améliore la performance prédictive globale du modèle.

Une autre méthode que nous avons utilisée est *la machine à vecteurs de support (SVM)*. Le *SVM* est un algorithme de classification qui cherche à trouver l’hyperplan optimal qui sépare les données en classes distinctes. Pour ce faire, il maximise la marge entre les points de données de différentes classes, offrant ainsi une séparation plus robuste et efficace. Dans nos expérimentations, nous avons utilisé le *noyau radial de base (RBF)*, qui est particulièrement adapté pour gérer des relations non linéaires entre les caractéristiques des données. Le noyau *RBF* transforme les données d’entrée dans un espace de dimension plus élevée où un hyperplan linéaire et peut être utilisé pour la classification. De plus, nous avons limité le nombre d’itérations à 20 pour contrôler la complexité computationnelle et assurer une convergence plus rapide du modèle.

En plus de ces méthodes d’apprentissage machine, nous avons également utilisé un modèle d’apprentissage profond, *tempCNN* (*Temporal Convolutional Neural Network*), pour capturer les variations temporelles complexes des pixels. *tempCNN* est particulièrement efficace pour analyser les séries temporelles et les données séquentielles. Dans notre cas, nous avons configuré le *tempCNN* avec plusieurs couches convolutives, chacune suivie de couches de *pooling* et de *dropout* pour éviter le surapprentissage. Les paramètres spécifiques incluent une taille de noyau de 5, un taux de *dropout* de 0,3 et l’utilisation de l’optimiseur *Adam* avec un taux d’apprentissage de 10^{-4} avec le reste de ces paramètres par défaut ($\beta_1 = 0.9$ et $\beta_2 = 0.999$). Cette architecture nous permet de modéliser les relations temporelles des données de manière efficace et de capturer des caractéristiques complexes qui seraient difficiles à détecter avec des modèles traditionnels. L’apprentissage est arrêté avec la technique d’arrêt précoce (*early stopping*) avec un nombre de patience de 10. Nous avons aussi entraîné le modèle avec une carte graphique de type NVIDIA RTX 4070 doté de 12 Go de mémoire.

Pour la mise en œuvre de ces algorithmes, nous avons utilisé la bibliothèque ***scikit-learn*** et ***Torch***, qui offre respectivement un ensemble complet d’outils pour l’apprentissage machine et profond en ***Python***. Ces deux bibliothèques nous ont permis de facilement accéder à des implémentations robustes et optimisées des modèles utilisés, ainsi que de nombreuses autres fonctionnalités pour le pré-traitement des données, la sélection de modèles et l’évaluation de la performance.

Pour garantir une performance optimale des modèles de *machine learning* et de *deep learning*, nous avons normalisé les données en utilisant la méthode Min-Max. Cette technique consiste à redimensionner les valeurs des caractéristiques des pixels temporels dans une plage de [0, 1]. La normalisation Min-Max aide à éliminer les disparités entre les différentes échelles de données, facilitant ainsi l’apprentissage des modèles et améliorant leur convergence. La formule 3.2 permet le calcul de la normalisation :

$$X' = \frac{X - \min(X)}{\max(X) + \min(X)} \quad (3.2)$$

Nous allons dans la suite présenter et discuter les résultats obtenus par les modèles choisis. Nous allons illustrer la carte d’occupation du sol générés pour la partie de test de Toulouse et les deux régions d’Algérie, Bordj Bou Arréridj et Béjaïa.

3.4 Résultats et discussions

Après avoir entraîné le modèles, le tableau 3.1 présente les résultats des taux de classification et de l'écart-type de chacun des modèles. Le modèle *TempCNN* a démontré une performance supérieure avec un taux de classification de 85.09% et un écart-type de 0.12. Ces résultats indiquent que *TempCNN* n'est pas seulement précis, mais aussi très cohérent dans ses prédictions. En deuxième position, nous avons le modèle *KNN* qui a obtenu un taux de classification de 78.98% et un écart-type de 0.63. Bien que son taux de classification soit inférieur à celui de *TempCNN*, il reste relativement élevé. Le modèle de *Forêt aléatoire* se classe en troisième position avec un taux de classification de 76.44% et un écart-type de 0.35. Bien que son taux de classification soit légèrement inférieur à celui de *KNN*, son écart-type est inférieur, ce qui indique une plus grande cohérence dans les prédictions. Enfin, le modèle *SVM* a montré des performances nettement inférieures aux autres, avec un taux de classification de seulement 12.99% et le plus grand écart-type de 1.29. Par contre, les paramètres du *SVM* peuvent être modifiés pour qu'il puisse converger plus et donner des scores plus performants. Un point important qui est le temps d'entraînement et d'inférence de ces modèles. Le modèle qui a pris le plus de temps à s'entraîner est *TempCNN*. Les autres modèles s'entraînent plus rapidement que *TempCNN*. Tandis que l'inférence, le *Forêt aléatoire* est le plus rapide parmi les autres.

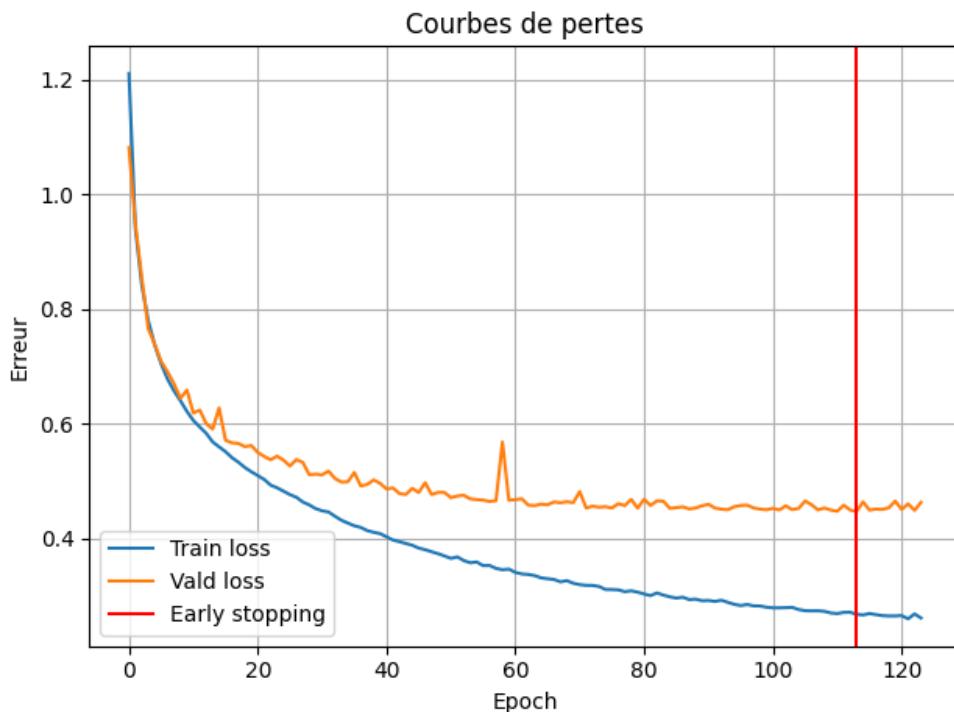


FIGURE 3.6 – Courbe d'apprentissage du modèle *TempCNN*.

La figure 3.6 est la courbe d'apprentissage qui représente les performances de notre modèle *TempCNN* au fil des époques. Sur l'axe des abscisses (x), nous avons le nombre d'époques. L'axe des ordonnées (y) représente l'erreur (ou perte). Les courbes de pertes montrent comment le modèle apprend pendant l'entraînement. La courbe bleu correspond à la perte d'entraînement (“*Train loss*”). Elle a une tendance à la baisse de l'erreur à mesure que le modèle apprend. Plus le nombre d'époques augmente, plus la perte diminue. Quant à la courbe orange, cette dernière représente la perte de validation (“*Valid loss*”). Elle suit également une tendance à la baisse, mais avec quelques oscillations. Cela indique que le modèle généralise bien sur de nouvelles données qui ne sont pas utilisées dans l'entraînement. L'arrêt précoce (la ligne verticale rouge) est une technique importante pour garantir que le modèle ne s'adapte pas trop spécifiquement aux données d'entraînement et conserve sa capacité à généraliser. En résumé, notre modèle *TempCNN* apprend efficacement et généralise correctement.

TABLEAU 3.1 – Évaluation quantitave des modèles (Taux de classification – TC, écart-type – ET).

Modèle	TC	ET
KNN	78.98	0.63
Forêt aléatoire	76.44	0.35
SVM	12.99	1.29
TempCNN	85.09	0.12

Concernant le tableau 3.2 qui illustre les résultats de la précision, rappel et le f1-score de chaque modèle pour chaque classe. D'après l'analyse du tableau, il est clair que le modèle *TempCNN* surpassé les autres modèles en termes de score F1 pour presque toutes les classes. Cela signifie que *TempCNN* a démontré une précision et une exhaustivité exceptionnelles dans la prédiction de ces classes, ce qui se traduit par un *score F1* élevé. Cependant, il est important de noter une exception notable à cette tendance générale. Pour la classe spécifique des *Tubercules/Racines*, c'est le modèle *KNN* qui a obtenu le *score F1* le plus élevé. Bien que *TempCNN* soit le modèle le plus performant dans l'ensemble, le choix du modèle optimal peut dépendre de la classe spécifique à prédire. Dans le cas des *Tubercules/Racines*, par exemple, *KNN* serait le choix préféré. Cette analyse souligne l'importance de considérer les performances spécifiques à chaque classe lors de l'évaluation des modèles.

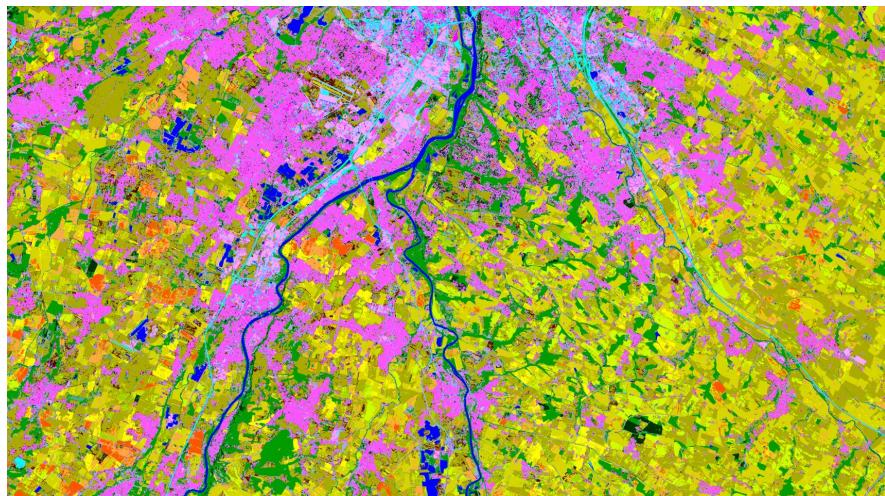
Modèle	KNN			RF			SVM			TempCNN		
	R	P	F1	R	P	F1	R	P	F1	R	P	F1
Urbain dense	76,68	71,98	74,26	73,21	76,69	74,91	16,61	03,72	06,08	89,97	80,81	85,14
Urbain diffus	56,97	53,85	55,36	58,39	54,73	56,50	01,90	06,45	02,94	62,65	73,61	67,69
Zones indus. et comm.	82,54	76,53	79,42	82,48	76,59	79,42	16,17	52,26	24,70	88,59	82,41	85,39
Routes	69,46	69,95	69,70	70,38	66,93	68,61	24,63	31,81	27,77	79,39	79,53	79,46
Colza	93,75	90,06	91,87	89,48	87,56	88,51	14,65	17,68	16,02	96,08	95,43	95,75
Céréales à paille	91,28	87,42	89,31	88,61	82,90	85,66	07,67	21,88	11,36	93,16	91,61	92,38
Protéagineux	89,32	85,51	87,37	82,60	84,30	83,44	01,97	14,09	03,46	91,52	91,07	91,29
Soja	90,15	89,24	89,69	84,42	88,84	86,57	09,13	19,14	12,36	92,51	92,25	92,38
Tournefort	76,62	89,46	82,55	75,03	79,96	77,42	09,10	23,67	13,14	83,76	91,16	87,30
Mais	95,36	92,47	93,89	91,34	93,89	92,60	10,66	24,00	14,76	96,53	93,54	95,01
Tubercules/Racines	94,84	90,01	92,36	94,15	90,57	92,33	73,73	72,25	72,99	99,68	79,91	88,70
Prairie	59,93	70,82	64,92	59,09	60,96	60,01	04,41	10,78	06,26	68,37	82,73	74,87
Vergers	66,69	61,84	64,17	68,30	56,02	61,55	07,00	25,18	10,95	76,09	69,46	72,62
Vignes	64,71	67,68	66,16	45,55	68,91	54,85	16,24	06,17	08,95	82,26	71,93	76,75
Forêts de feuillus	78,23	84,25	81,13	79,92	80,34	80,13	05,34	41,31	09,47	81,70	87,64	84,57
Forêts de conifères	66,47	75,77	70,82	60,28	75,06	66,87	24,10	11,25	15,34	83,88	73,26	78,21
Landes ligneuses	86,88	66,10	75,08	70,21	82,46	75,84	69,18	02,58	04,97	95,54	76,45	84,93
Eau	92,53	96,48	94,46	91,67	95,83	93,70	50,79	59,78	54,92	96,47	96,05	96,26
Serres agricole	65,48	85,26	74,08	60,38	89,27	72,03	10,90	23,32	14,86	93,30	68,36	78,91

TABLEAU 3.2 – Résultats de la précision, le rappel et le f1-score de chaque classe des différents modèles.

En plus de l'évaluation quantitative, nous vous présentons maintenant une évaluation qualitative des résultats obtenus par *TempCNN* sur la région de test de Toulouse et les régions algérienne. La figure 3.7 présente les résultats avec le modèle *TempCNN* (*a*), l'image depuis *Google Earth* (*b*) ainsi que la superposition de ces deux derniers (*c*) sur la région de Toulouse. Nous remarquons que la majorité des pixels sont bien classés en comparaison avec l'image Google Earth. Cela signifie aussi que les scores obtenus sont cohérents avec la carte d'occupation du sol générée.

Concernant les régions algériennes, la figure 3.8 présente les cartes d'occupation du sol et les vues satellites réelles obtenue avec Google Earth des régions de *Béjaya* (*b*) et *Bordj Bou Arréridj* (*e*), noté *BBA*. Les images provenant de Google Earth sont utilisées dans cette étude pour avoir une résolution spatiale plus précise. Elles sont utilisées pour comparer les images générées avec la réalité. Les images (*a*) et (*d*) montrent respectivement les résultats de l'inférence de *TempCNN* sur *Béjaya* et *BBA*. Nous observons que *TempCNN* a bien classifié les forêts dans la région de *Béjaya*. Toutefois, certaines régions agricoles sont classifiées comme zone urbaine dense. Nous observons aussi que la classe eau est bien reconnue dans cette même région (mer et fleuve). Concernant la région de *BBA*, nous constatons que la majorité des régions ont été classifiées comme zone urbaine. Ceci est dû à l'évolution temporelle stable de ces pixels temporels. La ville est classée comme urbain diffus. Les images (*c*) et (*f*) superposent les images générées par le modèle sur la carte Google Earth. Cette méthode nous a permis de faire une analyse précise des résultats obtenus.

Les résultats obtenus peuvent être améliorés. Les problèmes de classification auxquels nous sommes confrontés proviennent de la base d'entraînement, car celle-ci est issue d'une région différente de celle de l'Algérie. En effet, la végétation n'évolue pas de la même manière entre la France et l'Algérie, et le climat joue un rôle crucial dans le maintien et l'évolution de la végétation. Les conditions climatiques, telles que la température, les précipitations et l'humidité, varient considérablement entre ces deux pays. La France, avec son climat tempéré, et l'Algérie, avec son climat principalement méditerranéen et désertique, offrent des environnements très différents pour la végétation. Par conséquent, une base d'entraînement adaptée à la France peut ne pas être représentative des conditions algériennes, ce qui conduit à des erreurs de classification. Pour améliorer la précision des résultats, il est essentiel de créer une base d'entraînement spécifique à l'Algérie. Cela pourrait inclure des données locales sur la flore, les cycles saisonniers et les particularités climatiques régionales. De plus, l'incorporation de techniques de normalisation et d'adaptation des modèles aux conditions locales pourrait également contribuer à améliorer la performance de la classification.



(a) résultat TempCNN -Toulouse



(b) google earth -Toulouse



(c) superposition((a), (b)) -Toulouse

FIGURE 3.7 – différence entre l'image depuis google earth et l'inférence du modèle TempCNN sur la région Toulouse

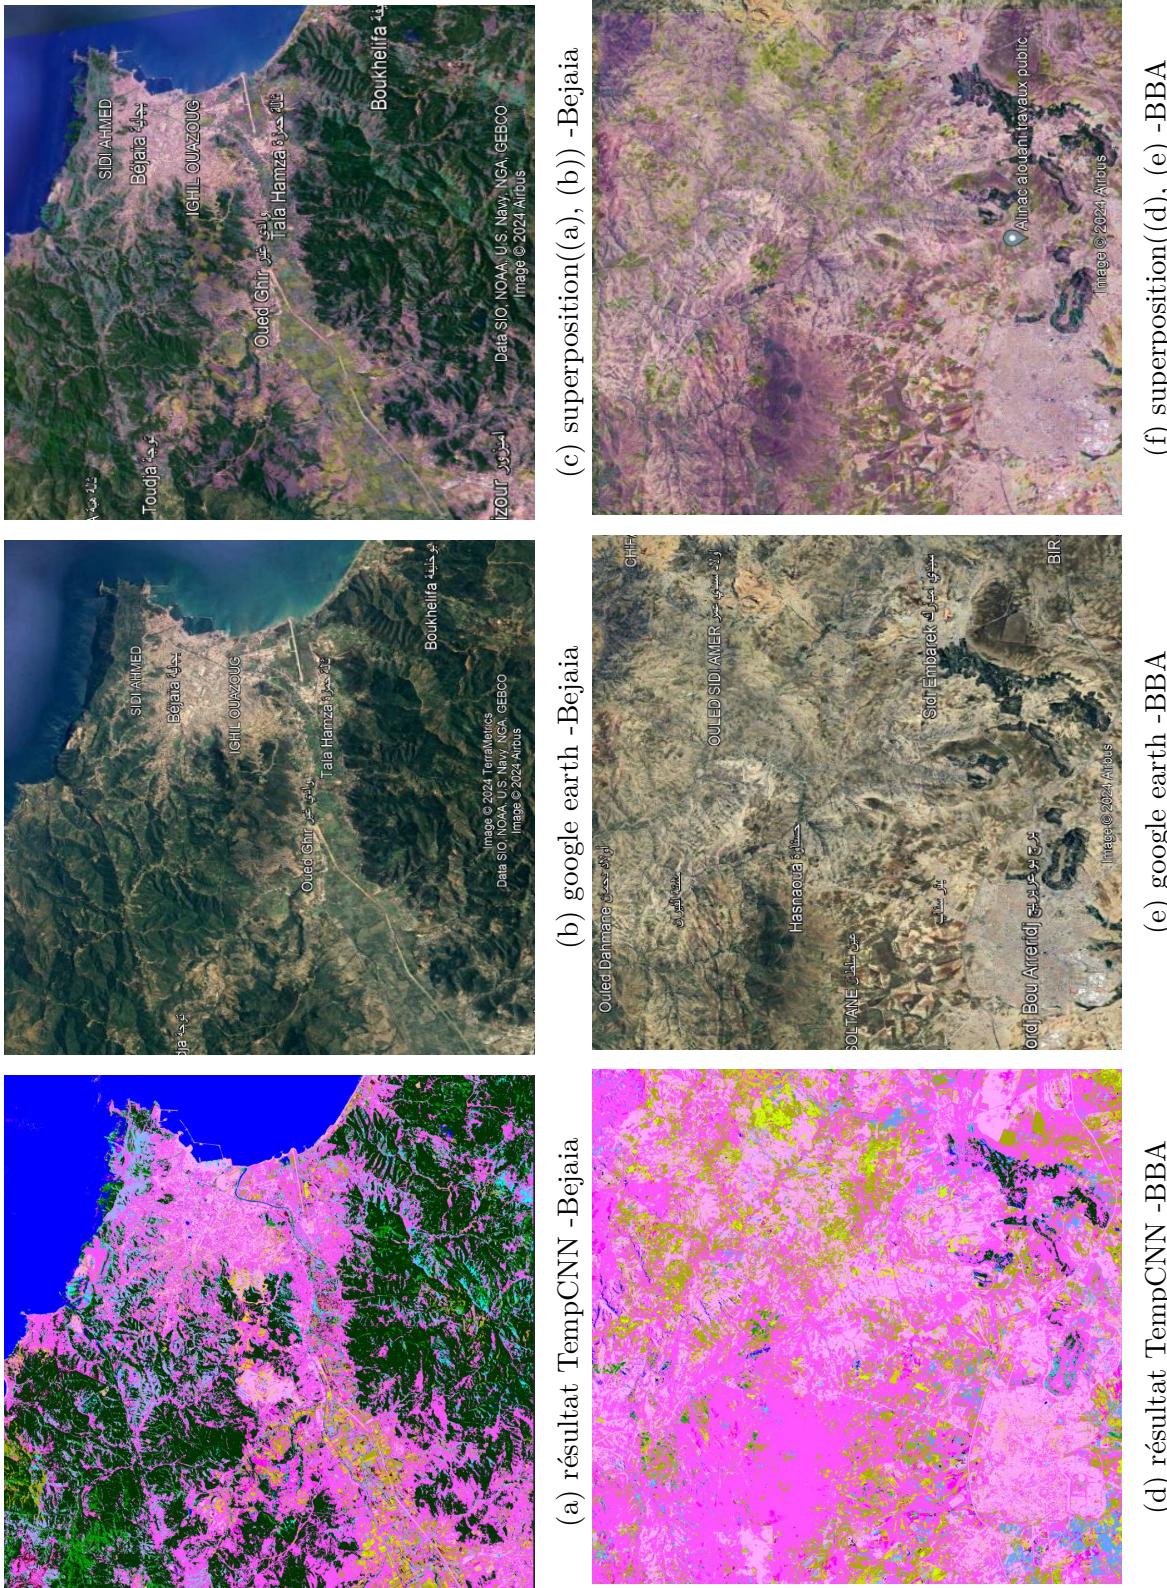


FIGURE 3.8 – différence entre l'image depuis google earth et l'inférence du modèle TempCNN sur la région de Bejaia et BBA

Chapitre 4

Application web

Dans ce chapitre, nous présentons une application web innovante permettant de visualiser les résultats obtenus de la carte d'occupation des sols sur une carte mondiale. Cette application a été conçue pour offrir une expérience utilisateur intuitive et interactive, facilitant l'exploration des données géographiques pour les utilisateurs de tous niveaux de compétence.

4.1 Technologies Utilisées

Le développement de l'application s'est appuyé sur des technologies web de base et des outils open source pour garantir flexibilité et performance.

- **HTML** : Utilisé pour structurer le site web, offrant une base solide pour le contenu.
- **CSS** : Employé pour styliser l'application, assurant une présentation visuellement attrayante et une interface utilisateur conviviale.
- **JavaScript** : Implémenté pour ajouter des fonctionnalités interactives, permettant une manipulation dynamique de la carte.
- **Python** : Utilisé pour le backend, gérant les opérations serveur et la logique métier de manière efficace et sécurisée.

4.2 Bibliothèque Leaflet et OpenStreetMap

Pour l'affichage de la carte, nous avons utilisé la bibliothèque Leaflet de JavaScript. Leaflet est une bibliothèque open source populaire qui facilite l'intégration de cartes interactives sur les sites web. En conjonction avec OpenStreetMap (OSM), Leaflet permet de superposer les cartes d'occupation des sols générées par notre modèle le plus performant sur une base de carte mondiale. La figure 4.1 illustre la carte OSM.



FIGURE 4.1 – Exemple d'intégration de Leaflet avec OpenStreetMap

4.3 Backend et FastAPI

Pour le backend de l'application, nous avons opté pour Python et la bibliothèque FastAPI. Cette dernière est connue pour sa capacité à créer des API rapides et performantes, essentielles pour les applications web nécessitant des interactions en temps réel. L'utilisation de FastAPI simplifie également le développement et la maintenance des API, améliorant ainsi l'efficacité globale du projet. La figure 4.2 illustre le processus que nous avons utilisés pour la réalisation du backend.

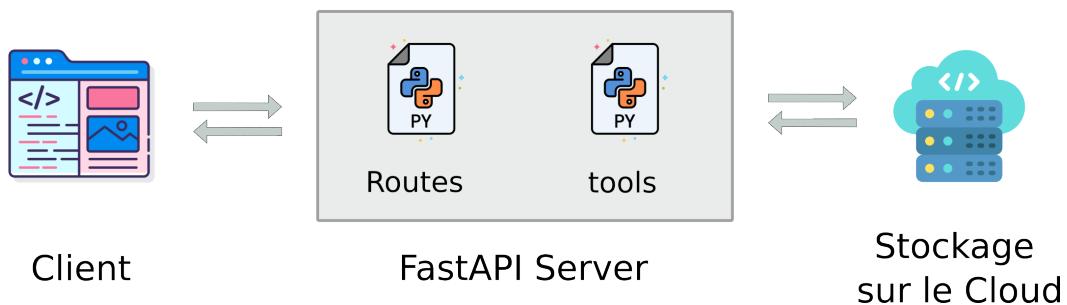


FIGURE 4.2 – Architecture du backend avec FastAPI

Notre backend utilise plusieurs routes pour fournir des fonctionnalités spécifiques de l'application. Par exemple, une route principale ("/") renvoie simplement la page d'accueil de l'application en utilisant la fonction `render_template` pour afficher le fichier `index.html`.

Une autre route ("/zoom/<city>") permet de zoomer sur une ville spécifique. Cette route accepte un nom de ville en tant que paramètre, vérifie les coordonnées géogra-

phiques prédéfinies pour cette ville, et renvoie ces coordonnées en format JSON. Cela permet à l'application de centrer la carte sur la ville sélectionnée par l'utilisateur.

De plus, nous avons une route ("/`overlay_image/<city> / <imageType>`") qui superpose une image de couverture des sols sur la carte. Pour ce faire, le backend lit les informations géoréférencées de l'image de couverture des sols en utilisant GDAL et renvoie les coordonnées des coins de l'image en format JSON. Si l'image n'est pas disponible pour la ville sélectionnée, un message d'erreur est retourné.

Enfin, une route ("/`send_image/<city> / <imageType>`") permet de renvoyer l'image de couverture des sols pour une ville donnée directement depuis le serveur. Cette fonctionnalité est cruciale pour l'affichage correct et dynamique des cartes dans l'application.

Voici une description des fonctionnalités fournies par notre backend :

- **Route principale** ("`/`") : Renvoie la page d'accueil de l'application.
- **Route de zoom** ("/`zoom/<city>`") : Fournit les coordonnées géographiques pour centrer la carte sur une ville spécifique.
- **Route de superposition de la couverture des sols** ("/`overlay_image/<city> / <imageType>`") : Fournit les coordonnées géoréférencées de l'image de couverture des sols pour une ville spécifique.
- **Route d'envoi d'image** ("/`send_image/<city> / <imageType>`") : Envoie l'image de couverture des sols pour une ville spécifique.

L'architecture du backend avec FastAPI permet une gestion efficace des demandes des utilisateurs et une intégration fluide avec la partie frontend de l'application, assurant ainsi une expérience utilisateur optimale.

4.4 Géoréférencement et Affichage Correct

Une attention particulière a été portée au géoréférencement des images. Nous avons intégré une bibliothèque de géographie, GDAL (Geospatial Data Abstraction Library), pour lire et écrire les informations de géoréférencement, garantissant ainsi que les cartes générées s'affichent correctement dans la zone géographique souhaitée. Cette précision est cruciale pour assurer la fiabilité et l'utilité des données présentées.

Pour ce faire, nous utilisons un script Python qui ouvre le fichier d'image et récupère son système de coordonnées d'origine. Ensuite, le script crée un nouveau système de coordonnées (WGS 84) et initialise un objet de transformation pour convertir les coordonnées de l'ancien système vers le nouveau. Il calcule les coordonnées géographiques (latitude et longitude) des coins de l'image (haut-gauche, haut-droite, bas-gauche, bas-droite) en utilisant les informations de géotransformation de l'image. Enfin, le script retourne les coordonnées géographiques des coins de l'image, ce qui permet un affichage correct et précis des cartes sur la carte mondiale.

Grâce à l'utilisation de GDAL et de ce processus de géoréférencement, nous garantissons une précision géographique élevée pour les images cartographiques affichées dans notre application.

4.5 Fonctionnalités de l'application

L'application offre plusieurs fonctionnalités clés qui améliorent l'expérience utilisateur :

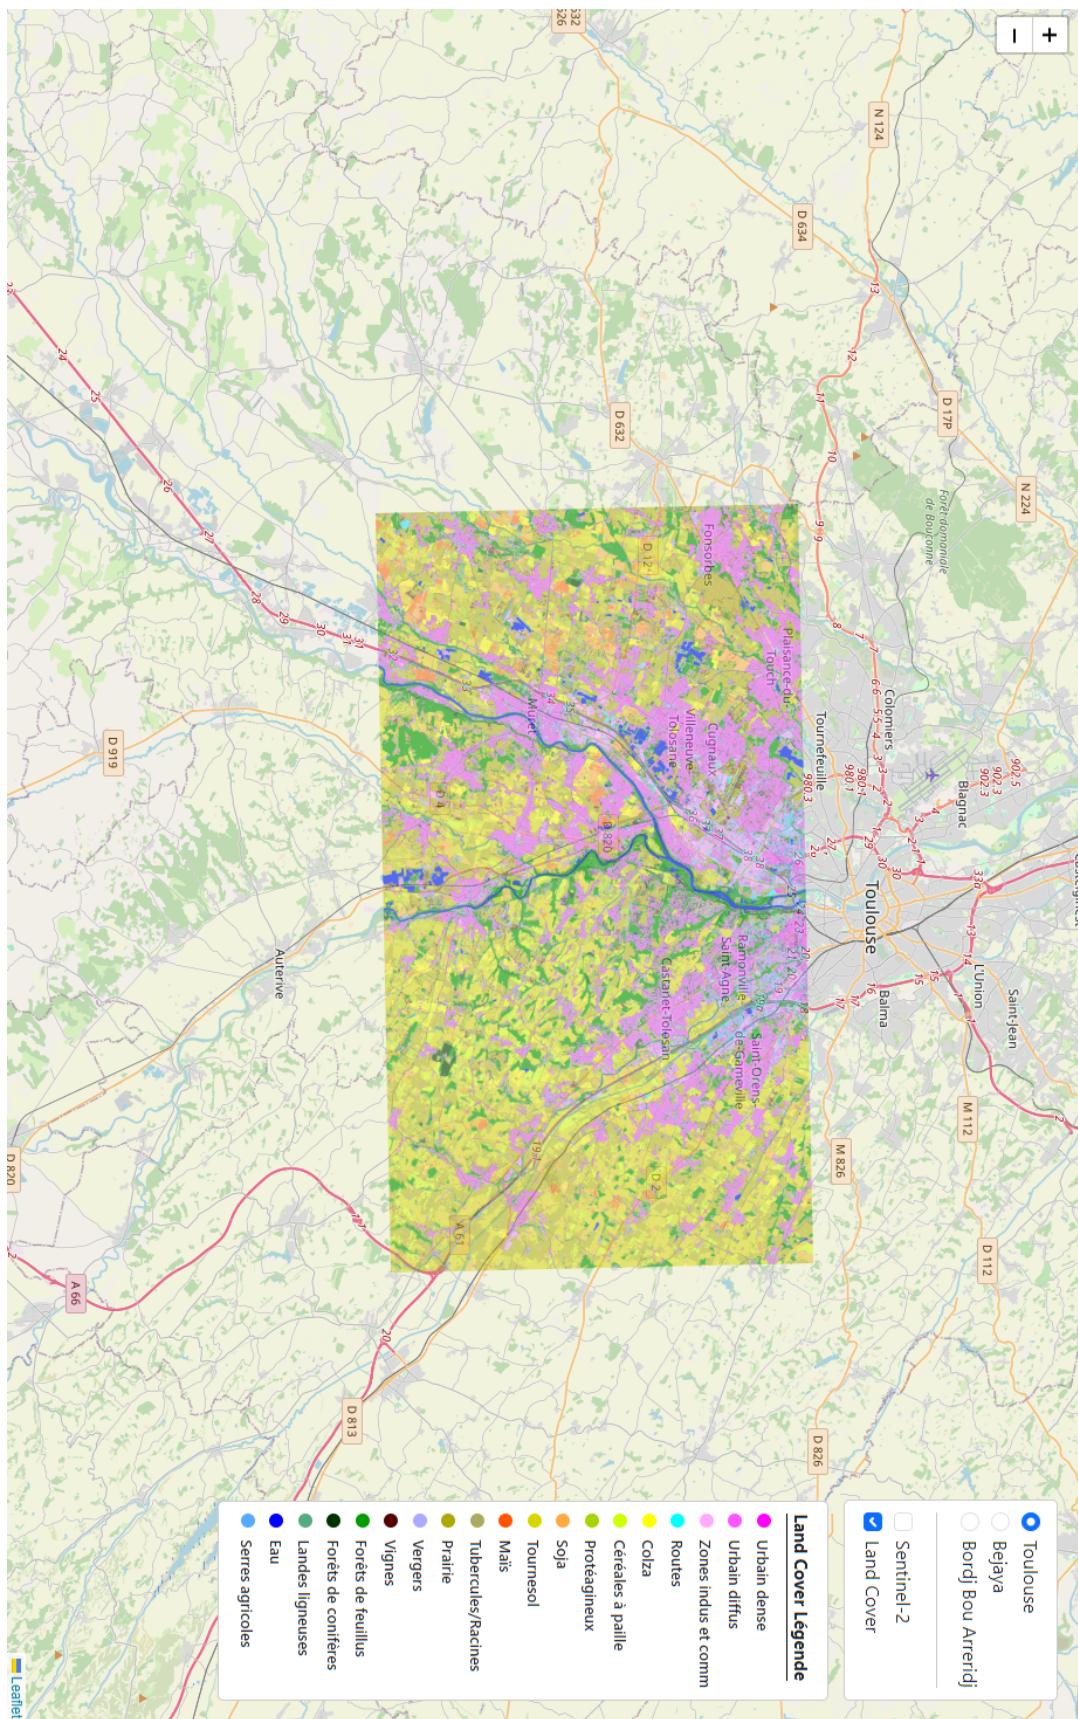
- **Navigation Interactive** : Les utilisateurs peuvent naviguer facilement à travers différentes régions du monde, explorant les données de manière fluide et intuitive.
- **Visualisation Dynamique** : Les changements dans l'occupation des sols peuvent être visualisés de manière interactive, aidant les utilisateurs à comprendre les dynamiques spatiales.
- **Interface Conviviale** : L'interface utilisateur est conçue pour être accessible aux non-experts, permettant à un large public d'explorer et d'interpréter les données géographiques sans difficulté.

4.6 Améliorations Futures

Pour continuer à améliorer l'application, plusieurs pistes peuvent être envisagées :

- **Intégration de Données Temps Réel** : Ajouter la capacité de visualiser les données en temps réel pour une analyse plus actuelle et réactive des dynamiques de l'occupation des sols.
- **Algorithmes de Machine Learning** : Intégrer des algorithmes de machine learning pour prédire les changements futurs de l'occupation des sols basés sur les tendances actuelles.
- **Personnalisation Utilisateur** : Offrir des options de personnalisation permettant aux utilisateurs de sauvegarder leurs vues préférées et de configurer des alertes pour les changements dans des zones spécifiques.
- **Support Multilingue** : Étendre l'application pour supporter plusieurs langues, rendant l'outil accessible à un public plus large à l'échelle mondiale.

Grâce aux technologies open source comme Leaflet, OpenStreetMap et FastAPI, nous avons assuré une grande flexibilité et une facilité d'extension de l'application pour des fonctionnalités futures. Le résultat de l'utilisation de ces outils est présenté dans la figure 4.3. Les outils open source offrent également une communauté de support active et des mises à jour régulières, garantissant la pérennité et l'innovation continue de l'application.



Chapitre 5

Conclusion et perspectives

Les travaux réalisés durant ce mémoire s'inscrivent dans le contexte de la génération des cartes d'occupation du sol. Les deux méthodes se basent sur extraction automatique de caractéristiques des pixels temporelles. La première méthode permet d'appliquer les méthodes apprentissage machine, dans notre cas, se sont : SVM, KNN et Random-Forest. La deuxième méthode se concentre sur les approches apprentissage profond, plus précisément le modèle *TempCNN*. Ce modèle a pour grand avantage d'acquisition d'une notion temporelle par rapport aux autres modèles d'apprentissage machine.

Les études expérimentales menées nous ont permis de comparer les méthodes proposées en les appliquant sur les mêmes jeux de données. Les résultats obtenus avec *TempCNN* dépassent largement ceux des autres modèles. Ce dernier a toutefois démontré sa limite dans le cas de la classification de la classe de type Tubercole/Racines.

Le développement de cette application web illustre comment l'intégration de technologies web de base et d'outils open source peut aboutir à une solution puissante et flexible pour la visualisation de données géographiques. En simplifiant l'accès et l'interprétation des cartes d'occupation des sols, cette application constitue une avancée majeure pour les utilisateurs cherchant à explorer les dynamiques environnementales à l'échelle mondiale.

Dans la continuité des travaux menés cette année, nous prévoyons d'optimiser et d'évaluer les modèles appliqués, notamment SVM, KNN, Random Forest et TempCNN, en utilisant divers paramétrages. Cette étape vise à améliorer la précision et l'efficacité de nos analyses de données géographiques. Une analyse approfondie du territoire algérien est indispensable pour construire une base de données locale, ce qui constitue une démarche essentielle pour obtenir des résultats plus fiables et pertinents. En créant cette base de données spécifique, nous pouvons mieux capturer les particularités régionales, telles que les variations climatiques, les types de sols et les dynamiques d'occupation des sols, ce qui enrichira la qualité de nos modèles prédictifs.

Bibliographie

- [1] C. Pelletier, G. I. Webb, and F. Petitjean, “Temporal convolutional neural network for the classification of satellite image time series,” *Remote Sensing*, vol. 11, no. 5, p. 523, 2019.
- [2] N. Hatami, Y. Gavet, and J. Debayle, “Classification of time-series images using deep convolutional neural networks,” in *International Conference on Machine Vision*, ser. SPIE Proceedings, A. Verikas *et al.*, Eds., vol. 10696. SPIE, 2017, p. 10696Y.
- [3] A. B. Pour, H. Ranjbar, M. Sekandari, M. Abd El-Wahed, M. S. Hossain, M. Hashim, M. Yousefi, B. Zoheir, J. D. T. Wambo, and A. M. Muslim, “2 - remote sensing for mineral exploration,” in *Geospatial Analysis Applied to Mineral Exploration*, A. B. Pour, M. Parsa, and A. M. Eldosouky, Eds. Elsevier, 2023, pp. 17–149.
- [4] D. García-Álvarez, M. T. Camacho Olmedo, J.-F. Mas, and M. Paegelow, *Land Use Cover Mapping, Modelling and Validation. A Background.* Cham : Springer International Publishing, 2022, pp. 21–33.
- [5] “Institut - ign,” <https://www.ign.fr/institut/une-carte-doccupation-du-sol-pour-faciliter-le-suivi-de-lartificialisation>, (consulté le 03/20/2024).
- [6] A. A. Barati, M. Zholideh, H. Azadi, J.-H. Lee, and J. Scheffran, “Interactions of land-use cover and climate change at global level : How to mitigate the environmental risks and warming effects,” *Ecological Indicators*, vol. 146, p. 109829, 2023.
- [7] M. Soliman, M. M. Morsy, and H. G. Radwan, “Assessment of implementing land use/land cover lulc 2020-esri global maps in 2d flood modeling application,” *Water*, vol. 14, no. 23, 2022.
- [8] L. Vilar, S. Herrera, E. Tafur-García, M. Yebra, J. Martínez-Vega, P. Echavarriá, and M. Martín, “Modelling wildfire occurrence at regional scale from land use/cover and climate change scenarios,” *Environmental Modelling and Software*, vol. 145, p. 105200, 2021.
- [9] E. Kalinicheva, “Unsupervised satellite image time series analysis using deep learning techniques,” Ph.D. dissertation, 09 2020.
- [10] C. Pelletier, “Cartographie de l’occupation des sols à partir de séries temporelles d’images satellitaires à hautes résolutionsidentification et traitement des données mal étiquetées,” Ph.D. dissertation, 12 2017.

- [11] F. Petitjean, J. Inglada, and P. Gançarski, “Satellite image time series analysis under time warping,” *IEEE Trans. Geosci. Remote. Sens.*, vol. 50, no. 8, pp. 3081–3095, 2012.
- [12] P. Héas and M. Datcu, “Modeling trajectory of dynamic clusters in image time-series for spatio-temporal reasoning,” *IEEE Trans. Geosci. Remote. Sens.*, vol. 43, no. 7, pp. 1635–1647, 2005.
- [13] F. Petitjean, C. Kurtz, N. Passat, and P. Gançarski, “Spatio-temporal reasoning for the classification of satellite image time series,” *Pattern Recognit. Lett.*, vol. 33, no. 13, pp. 1805–1815, 2012.
- [14] L. Khiali, M. Ndiath, S. Alleaume, D. Ienco, K. Ose, and M. Teisseire, “Detection of spatio-temporal evolutions on multi-annual satellite image time series : A clustering based approach,” *Int. J. Appl. Earth Obs. Geoinformation*, vol. 74, pp. 103–119, 2019.
- [15] J. Inglada, A. Vincent, M. Arias, B. Tardy, D. Morin, and I. Rodes, “Operational high resolution land cover map production at the country scale using satellite image time series,” *Remote. Sens.*, vol. 9, no. 1, p. 95, 2017.
- [16] J. W. Rouse and R. H. Haas, “Monitoring vegetation systems in the great plain with ERTS,” in *Third ERTS Symposium*, vol. 1. Washington DC : NASA, 1973, pp. 309–317.
- [17] C. J. Tucker, “Red and photographic infrared linear combinations for monitoring vegetation,” *Remote Sensing of the Environment*, vol. 8, pp. 127–150, 1979.
- [18] B.-C. Gao, “A normalized difference water index for remote sensing of vegetation liquid water from space,” *Remote Sensing of Environment*, vol. 58, pp. 257–266, 1996.
- [19] D. Lowe, “Object recognition from local scale-invariant features,” in *Proceedings of the Seventh IEEE International Conference on Computer Vision*, vol. 2, 1999, pp. 1150–1157 vol.2.
- [20] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *Int. J. Comput. Vis.*, vol. 60, no. 2, pp. 91–110, 2004.
- [21] R. M. Haralick, K. S. Shanmugam, and I. Dinstein, “Textural features for image classification,” *IEEE Trans. Syst. Man Cybern.*, vol. 3, no. 6, pp. 610–621, 1973.
- [22] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’05)*, vol. 1, 2005, pp. 886–893 vol. 1.
- [23] C. Dong, J. Liu, F. Xu, and C. Liu, “Ship detection from optical remote sensing images using multi-scale analysis and fourier HOG descriptor,” *Remote. Sens.*, vol. 11, no. 13, p. 1529, 2019.
- [24] T. Ojala, M. Pietikäinen, and D. Harwood, “A comparative study of texture measures with classification based on featured distributions,” *Pattern Recognition*, vol. 29, no. 1, pp. 51–59, 1996.
- [25] N. Gupta, G. V. Pillai, and S. Ari, “Change detection in optical satellite images based on local binary similarity pattern technique,” *IEEE Geosci. Remote. Sens. Lett.*, vol. 15, no. 3, pp. 389–393, 2018.

- [26] R. M. Haralick, K. Shanmugam, and I. Dinstein, “Textural features for image classification,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-3, no. 6, pp. 610–621, 1973.
- [27] I. T. Jolliffe, *Principal Component Analysis*, ser. Springer Series in Statistics. Springer, 2002.
- [28] A. Bailly, S. Malinowski, R. Tavenard, L. Chapel, and T. Guyet, “Dense bag-of-temporal-sift-words for time series classification,” in *Advanced Analysis and Learning on Temporal Data - First ECML PKDD Workshop, AALTD 2015, Porto, Portugal, September 11, 2015, Revised Selected Papers*, ser. Lecture Notes in Computer Science, A. D. Chouakria, J. A. V. Fernández, and P. Marteau, Eds., vol. 9785. Springer, 2015, pp. 17–30.
- [29] P. Coppin and M. E. Bauer, “Digital change detection in forest ecosystems with remote sensing imagery,” *Remote Sensing Reviews*, vol. 13, no. 3-4, pp. 207–234, 1996.
- [30] M. Chelali, C. Kurtz, A. Puissant, and N. Vincent, “Spatio-temporal stability analysis in satellite image times series,” in *Pattern Recognition and Artificial Intelligence - International Conference, ICPRAI 2020, Zhongshan, China, October 19-23, 2020, Proceedings*, ser. Lecture Notes in Computer Science, Y. Lu, N. Vincent, P. C. Yuen, W. Zheng, F. Cheriet, and C. Y. Suen, Eds., vol. 12068. Springer, 2020, pp. 484–499.
- [31] S. J. Russell and P. Norvig, *Artificial Intelligence : A Modern Approach*, 4th ed. Pearson, 2020.
- [32] L. R. Rabiner, “A tutorial on hidden markov models and selected applications in speech recognition,” *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989.
- [33] F. Adjailia, M. Ramdani, A. Rasamoelina, and P. Sincak, “Integration of 2d textural and 3d geometric features for robust facial expression recognition,” *Computing and Informatics*, vol. 40, pp. 988–1007, 12 2021.
- [34] S. Murala, R. Maheshwari, and B. Raman, “Local tetra patterns : A new feature descriptor for content-based image retrieval,” *IEEE transactions on image processing : a publication of the IEEE Signal Processing Society*, vol. 21, pp. 2874–86, 05 2012.
- [35] P. Scovanner, S. Ali, and M. Shah, “A 3-dimensional sift descriptor and its application to action recognition,” in *Proceedings of the 15th ACM international conference on Multimedia*. ACM, 2007, pp. 357–360.
- [36] N. Buch, J. Orwell, and S. Velastin, “3d extended histogram of oriented gradients (3dhog) for classification of road users in urban scenes,” *British Machine Vision Conference, BMVC 2009 - Proceedings*, 01 2009.
- [37] H. Wang, A. Kläser, C. Schmid, and C.-L. Liu, “Action recognition by dense trajectories,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2011, pp. 3169–3176.
- [38] H. Bay, T. Tuytelaars, and L. V. Gool, “Surf : Speeded up robust features,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2006, pp. 404–417.

- [39] X. Tan and B. Triggs, “Enhanced local texture feature sets for face recognition under difficult lighting conditions,” *IEEE Transactions on Image Processing*, vol. 19, no. 6, pp. 1635–1650, 2010.
- [40] M. Chelali, “Prise en compte de l’information spatiale et temporelle pour l’analyse de séquences d’images,” Theses, EDITE de Paris, Nov. 2021.
- [41] Y. Bengio and F. Gingras, “Recurrent neural networks for missing or asynchronous data,” in *Advances in Neural Information Processing Systems*, D. S. Touretzky, M. Mozer, and M. E. Hasselmo, Eds. MIT Press, 1995, pp. 395–401.
- [42] A. Graves and J. Schmidhuber, “Framewise phoneme classification with bidirectional lstm and other neural network architectures,” *Neural Networks*, vol. 18, no. 5-6, pp. 602–610, 2005.
- [43] M. Wollmer *et al.*, “Context-sensitive multimodal emotion recognition from speech and facial expression using bidirectional lstm modeling,” in *INTERSPEECH Annual Conference of the International Speech Communication Association*, T. Kobayashi, K. Hirose, and S. Nakamura, Eds. ISCA, 2010, pp. 2362–2365.
- [44] M. Russwurm and M. Korner, “Temporal vegetation modelling using long short-term memory networks for crop identification from medium-resolution multispectral satellite images,” in *IEEE Computer Vision and Pattern Recognition Workshops*. IEEE Computer Society, 2017, pp. 1496–1504.
- [45] D. Ienco *et al.*, “Land cover classification via multitemporal spatial data by deep recurrent neural networks,” *IEEE Geoscience and Remote Sensing Letters*, vol. 14, no. 10, pp. 1685–1689, 2017.
- [46] B. Huang *et al.*, “Large-scale semantic classification : Outcome of the first year of inria aerial image labeling benchmark,” in *IEEE International Geoscience and Remote Sensing Symposium*. IEEE, 2018, pp. 6947–6950.
- [47] H. I. Fawaz *et al.*, “Deep learning for time series classification : a review,” *Data Mining and Knowledge Discovery*, vol. 33, no. 4, pp. 917–963, 2019.
- [48] N. Marwan *et al.*, “Recurrence plots for the analysis of complex systems,” *Physics Reports*, vol. 438, no. 5, pp. 237–329, 2007.
- [49] Z. Wang and T. Oates, “Imaging time-series to improve classification and imputation,” in *International Joint Conference on Artificial Intelligence*, Q. Yang and M. J. Wooldridge, Eds. AAAI Press, 2015, pp. 3939–3945.
- [50] S. Nisar, O. U. Khan, and M. Tariq, “An efficient adaptive window size selection method for improving spectrogram visualization,” *Computational Intelligence and Neuroscience*, vol. 2016, pp. 6 172 453 :1–6 172 453 :13, 2016.
- [51] O. Russakovsky *et al.*, “Imagenet large scale visual recognition challenge,” *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.

Annexe A

Annexe

République Algérienne Démocratique et Populaire
Ministère de l'enseignement Supérieur et de la Recherche Scientifique
Université de Mohamed El Bachir El Ibrahimi de Bordj Bou Arréridj

Le nom commercial

Vita Earth

Image de marque commerciale



Titre du projet :

Génération de carte d'occupation du sol à partir de série temporelle d'images satellitaires

Projet pour l'obtention d'un diplôme-start-up dans le cadre de l'arrêté ministériel n°1275

Fiche d'informations :

À propos de l'équipe de supervision et de l'équipe de travail

- L'équipe d'encadrement :

équipe d'encadrement	
Spécialité : Informatique	L'encadrant principal (01) : ATTIA Safa

- L'équipe de travail :

Groupe de projet :	Spécialité :
CHELALI Anis	Technologie de l'information et de la communication
BOUGHABA Adnane	Technologie de l'information et de la communication
REZIG Ayoub	Technologie de l'information et de la communication

A.1 Axe 1 : Présentation du projet

A.1.1 Idée du projet

Nous avons entrepris de créer un système automatisé de cartographie de l'occupation des sols, en intégrant l'intelligence artificielle pour analyser les images satellitaires. Notre projet vise à répondre aux besoins croissants en gestion des ressources naturelles et en aménagement du territoire en Algérie, un pays confronté à des défis majeurs tels que l'urbanisation rapide, la déforestation et la perte de biodiversité. La conversion des terres agricoles et forestières en zones urbaines, ainsi que le manque de données précises, compliquent la planification et la gestion efficaces des ressources.

Pour remédier à ces problèmes, notre objectif est de produire des cartes précises et actualisées de l'occupation des sols. Cela permettra une meilleure gestion des territoires et une prise de décision éclairée. Nous utiliserons des modèles d'intelligence artificielle pour classifier les différentes zones de couverture terrestre à partir des images satellites de la constellation Sentinel-2, optimisés pour distinguer les zones urbaines, agricoles et forestières.

A.1.2 Valeurs proposées

- **La modernité** : Intégration de l'intelligence artificielle pour l'analyse des images satellitaires, offrant une méthode automatisée et précise de cartographie de l'occupation des sols à grande échelle.
- **La performance** : Fourniture de cartes d'occupation des sols actualisées et fiables, permettant une gestion efficace des territoires grâce à des informations précises.
- **L'adaptabilité** : Personnalisation des cartes pour répondre aux besoins spécifiques des clients, qu'il s'agisse de planification urbaine, de conservation des ressources naturelles ou de gestion agricole.
- **Accomplissement de la tâche** : Aide aux clients pour accomplir des tâches spécifiques liées à la gestion des territoires, comme la prédiction des rendements agricoles et le suivi des ressources en eau.
- **Réduction des coûts** : Diminution des coûts associés à la production manuelle de cartes et à la collecte de données.
- **Réduction des risques** : Minimisation des risques pour les clients en offrant des garanties sur la précision et la fiabilité des cartes.
- **Facilité d'accès** : Accès rapide et régulier aux cartes, permettant une utilisation plus large et efficace par différents utilisateurs.
- **Facilité d'utilisation** : Interprétation intuitive des cartes grâce à un code couleur clair, facilitant la compréhension des données.

A.1.3 Travail d'équipe

Ce projet combine à la fois des aspects de recherche et des applications pratiques, divisés en deux parties :

- **Partie recherche** : L'analyse des méthodes de l'état de l'art et la veille stratégique et technologique sont essentielles pour améliorer le moteur d'intelligence artificielle et optimiser les résultats de chaque itération.
- **Partie application** : Le développement et la mise en production du moteur d'intelligence artificielle sont cruciaux pour assurer une utilisation facile et efficace par les experts des clients.

Étant donné la taille réduite de notre équipe, chaque membre participe activement à ces deux volets, collaborant étroitement pour déterminer les prochaines étapes à suivre.

A.1.4 Objectifs du projet

Le projet a pour objectif de développer des produits et services de cartographie d'occupation du sol adaptés à divers secteurs tels que les gouvernements, les ONG et les entreprises privées, tout en offrant des services de mise à jour régulière des cartes pour une surveillance continue. Pour accroître nos parts de marché, nous nous concentrerons sur des secteurs spécifiques tels que l'agriculture de précision, la planification urbaine, la gestion des ressources naturelles et la surveillance environnementale. Notre stratégie d'innovation et de différenciation comprend l'introduction de fonctionnalités avancées en intelligence artificielle et traitement d'images satellitaires, ainsi que la personnalisation de nos produits et services pour répondre aux besoins spécifiques des clients. Enfin, nous étendons nos activités commerciales à l'international, en ciblant des marchés émergents où la demande pour des cartes d'occupation du sol est en forte croissance.

A.1.5 Un échéancier pour la réalisation du projet

Travaux			Mois							
			1	2	3	4	5	6	7	8
1	Acquisition de données		✓	✓	✓					
2	Analyse et prétraitement			✓	✓					
3	Entraînement du modèle					✓				
4	Adaptation et ajustement du modèle					✓	✓			
5	Évaluation du modèle						✓	✓		
6	Inférence et génération des cartes d'occupation du sol							✓		
7	Réalisation d'application web								✓	✓

A.2 Axe 2 : les aspects innovant

les aspects innovant de notre projet sont :

- utilisation de l'intelligence artificielle pour la génération de carte d'occupation du sol, en développant des algorithmes automatisés pour la détection des changements, facilitant la surveillance continue et la mise à jour en temps réel des cartes.
- Utilisation des données issue de Sentinel-2, qui offrent une résolution spatiale et temporelle élevée.
- permet aux clients d'acheter des cartes et des analyses spécifiques. Si vous avez besoin d'une carte pour une région précise ou d'une analyse particulière.
- Développement d'interfaces utilisateur interactives pour permettre aux experts et non-experts de visualiser et d'interpréter facilement les cartes générées.

A.3 Axe 3 : analyse stratégique du marché

A.3.1 Identification du Marché Cible et du Marché Potentiel

Marché Potentiel :

Les individus ou les organisations qui ont besoin de cartes d'occupation des sols

Marché Cible :

- **Gouvernements et Institutions Publiques** : Les agences gouvernementales (ministères de l'agriculture, de l'environnement et de l'urbanisme) nécessitent des cartes d'occupation du sol pour la planification et la gestion des ressources.
- **Entreprises Privées** : Les entreprises dans les secteurs de l'agriculture, planification urbaine et les études environnementales.
- **Instituts de Recherche et Universités** : Faire avancer la recherche et le développement dans le domaine de la télédétection.

Les entités mentionnées ont des besoins spécifiques et continus pour des données précises et actualisées sur l'occupation du sol.

A.3.2 Mesure de l'Intensité de la Concurrence

Au niveau de l'Algérie, il n'existe actuellement aucune entreprise spécialisée dans la génération de cartes d'occupation des sols à partir d'images satellites. Cependant, à l'échelle internationale, plusieurs entreprises sont en tête dans ce domaine émergent. tels que :

Google Earth Engine : Plateforme d'analyse géospatiale très populaire pour les recherches et applications en sciences environnementales.

- **Forces** : Accès gratuit à des outils puissants d'analyse géospatiale, large communauté de soutien.
- **Faiblesses** : Peut nécessiter une expertise technique pour une utilisation optimale, dépendance à l'infrastructure cloud de Google.

A.3.3 Stratégies de Marketing

- **Marketing de contenu** : Créer des blogs, des études de cas, des vidéos expliquant les avantages de l'utilisation des cartes d'occupation du sol.
- **Réseaux Sociaux** : Utiliser les plateformes comme LinkedIn, Twitter, et Facebook pour atteindre les décideurs et les influenceurs du secteur.
- **Participation à des Conférences et Salons** :
 - **Événements Spécialisés** : Participer à des conférences et salons sur la géospatiale, l'environnement, l'agriculture et l'urbanisme.
 - **Présentations et Ateliers** : Animer des ateliers et des présentations pour démontrer l'efficacité des solutions proposées.
- **Approche Directe** :
 - **Vente Directe** : Contacter directement les clients potentiels (gouvernements, entreprises, ONG) pour proposer des solutions sur mesure.
 - **Démo et Essais** : Offrir des démonstrations gratuites et des périodes d'essai pour prouver la valeur des produits et services.

A.4 Axe 4 : le plan de production et d'organisation

A.4.1 Processus de Production

- Acquisition de données de vérité terrain
- Acquisition des séries temporelles d'images satellitaires à partir de sentinel-2
- Prétraitement et analyse des données
- Application de modèles de classification supervisée pour identifier les différentes classes d'occupation du sol.
- Inférence et génération des cartes d'occupation du sol

A.4.2 Approvisionnement

Notre projet nécessite l'accès à des données satellitaires de haute qualité et de grande précision. Pour répondre à ces exigences, nous nous appuyons sur Theia Land, reconnu pour la fiabilité et la régularité de ses mises à jour de données.

A.4.3 Main d'Œuvre

Ce projet présente un potentiel significatif pour la création de divers postes de travail spécialisés. En effet, l'implémentation de modèles d'apprentissage profond pour la classification des images, le développement de l'interface utilisateur intuitive, la gestion des données géospatiales, et l'application des connaissances géographiques spécifiques à la télédétection sont autant de domaines nécessitant une expertise pointue et diversifiée. Voici les postes à pourvoir :

- **Ingénieurs en intelligence artificiels** : Développement et entraînement des modèles de apprentissage profond pour la classification des images.
- **Développeurs Web** : Concevoir l'interface utilisateur (UI) du site web, intégrer les fonctionnalités d'interprétation des résultats et de visualisation des cartes et construire l'API pour gérer les requêtes utilisateur, intégrer les algorithmes de traitement des données géospatiales et d'analyse des résultats.
- **Spécialistes en SIG (Systèmes d'Information Géographique)** : Gestion et manipulation des données géospatiales.
- **Géographe spécialisé en télédétection** : Expérience dans l'application des connaissances géographiques à des problèmes spécifiques , capacité à conseiller sur les meilleures pratiques pour l'utilisation des cartes d'occupation des sols.
- **Support Client et Formation** : Assurer la formation des utilisateurs et offrir un support technique.

A.4.4 Identification des Principales Entreprises Participants au Projet

- **Theia Land** : Fournisseur de données satellitaires haute résolution.
- **Instituts de Recherche en Géosciences** : Collaboration pour des projets de recherche et développement.
- **Les incubateurs d'entreprises universitaires** : Offrir aux étudiants une expérience pratique en complément de leur formation théorique et encourager la recherche et le développement de nouvelles technologies et idées.
- **Ministères de l'Agriculture, de l'Environnement, et de l'Urbanisme** : Collaboration pour des projets de gestion des ressources et de planification du terrain.
- **ONG Environnementales** : Partenariats pour des projets de conservation et de gestion durable des terres.

A.5 Axe 5 : le plan financier

A.5.1 Les Coûts

Matière	Montant annuel (DA)
Matériel informatique	1 200 000.00
Coûts de location	600 000.00
Frais internet , électricité , ...	1 200 000.00
Infrastructure cloud (serveurs , stockage , etc.)	200 000.00
Développement de l'interface web	-
Hébergement web et maintenance des serveurs	250 000.00
Recherche et développement	-
Marketing et promotion	500 000.00
Salaires des employés	4 000 000.00
Assurance des employés	211 200.00
Total	8 116 120.00

A.5.2 Chiffre d'affaire (APPROXIMATIVE)

Service Standard :

Contrats annuels avec des ONG et ministères : Tarifs basés sur la superficie

- Superficie de 0 à 5 000 hectares : 250 000.00 DA par an
- Superficie de 5001 à 10 000 hectares : 450 000.00 DA par an
- Superficie de 1 0001 à 50 000 hectares : 1 000 000.00 DA par an
- Superficie de 50 001 à 100 000 hectares : 1 800 000.00 DA par an
- Superficie de 100 000 à 200 000 hectares : 2 500 000.00 DA par an

Service Personnaliser :

Vente de cartes selon le besoin du client + Services de conseils et d'analyse des données : + 20 % du prix original

Point de Vue Optimiste :

- 3 Contrats standard avec des ONG : Superficie de 10001 à 50000 hectares.
- 2 Contrats Personnaliser avec des ONG : Superficie de 10001 à 50000 hectares.
- 2 Contrats Personnaliser avec des Ministères : Superficie de 100000 à 200000 hectares

Mois(N)	Chiffre d'affaire	Mois(N+1)	Chiffre d'affaire
Janvier	950 000.00 DA	Janvier	1 116 666.00 DA
Février	950 000.00 DA	Février	1 116 666.00 DA
Mars	950 000.00 DA	Mars	1 116 666.00 DA
Avril	950 000.00 DA	Avril	1 116 666.00 DA
Mai	950 000.00 DA	Mai	1 116 666.00 DA
Juin	950 000.00 DA	Juin	1 116 666.00 DA
Juillet	950 000.00 DA	Juillet	1 116 666.00 DA
Août	950 000.00 DA	Août	1 116 666.00 DA
Septembre	950 000.00 DA	Septembre	1 116 666.00 DA
Octobre	950 000.00 DA	Octobre	1 116 666.00 DA
Novembre	950 000.00 DA	Novembre	1 116 666.00 DA
Décembre	950 000.00 DA	Décembre	1 116 666.00 DA
total	11400000.00 DA	total	13400000.00 DA

Point de Vue pessimiste :

- 1 Contrats standard avec des ONG : Superficie de 10001 à 50000 hectares.
- 1 Contrats Personnaliser avec des ONG : Superficie de 10001 à 50000 hectares.
- 2 Contrats Personnaliser avec des Ministères : Superficie de 100000 a 200000 hectares.

Mois(N)	Chiffre d'affaire	Mois(N+1)	Chiffre d'affaire
Janvier	683 333.00 DA	Janvier	766 666.00 DA
Février	683 333.00 DA	Février	766 666.00 DA
Mars	683 333.00 DA	Mars	766 666.00 DA
Avril	683 333.00 DA	Avril	766 666.00 DA
Mai	683 333.00 DA	Mai	766 666.00 DA
Juin	683 333.00 DA	Juin	766 666.00 DA
Juillet	683 333.00 DA	Juillet	766 666.00 DA
Août	683 333.00 DA	Août	766 666.00 DA
Septembre	683 333.00 DA	Septembre	766 666.00 DA
Octobre	683 333.00 DA	Octobre	766 666.00 DA
Novembre	683 333.00 DA	Novembre	766 666.00 DA
Décembre	683 333.00 DA	Décembre	766 666.00 DA
total	8200000.00 DA	total	9 200 000.00 DA

A.6 Axe 6 : le prototype expérimental

Voici le premier prototype A.1 concernant les cartes d'occupation du sol les deux régions : *Béjaïa*, *Bordj Bou Arreridj* et Toulouse obtenues grâce à l'apprentissage profond. Chaque carte affiche différentes couleurs qui représentent différents types d'occupation du sol. Quant à la figure A.2 illustre notre application web qui présente notre premier prototype ainsi que la légende du code couleur correspondant aux classes sur les cartes. Cette légende est essentielle pour comprendre ce que chaque couleur sur les cartes signifie

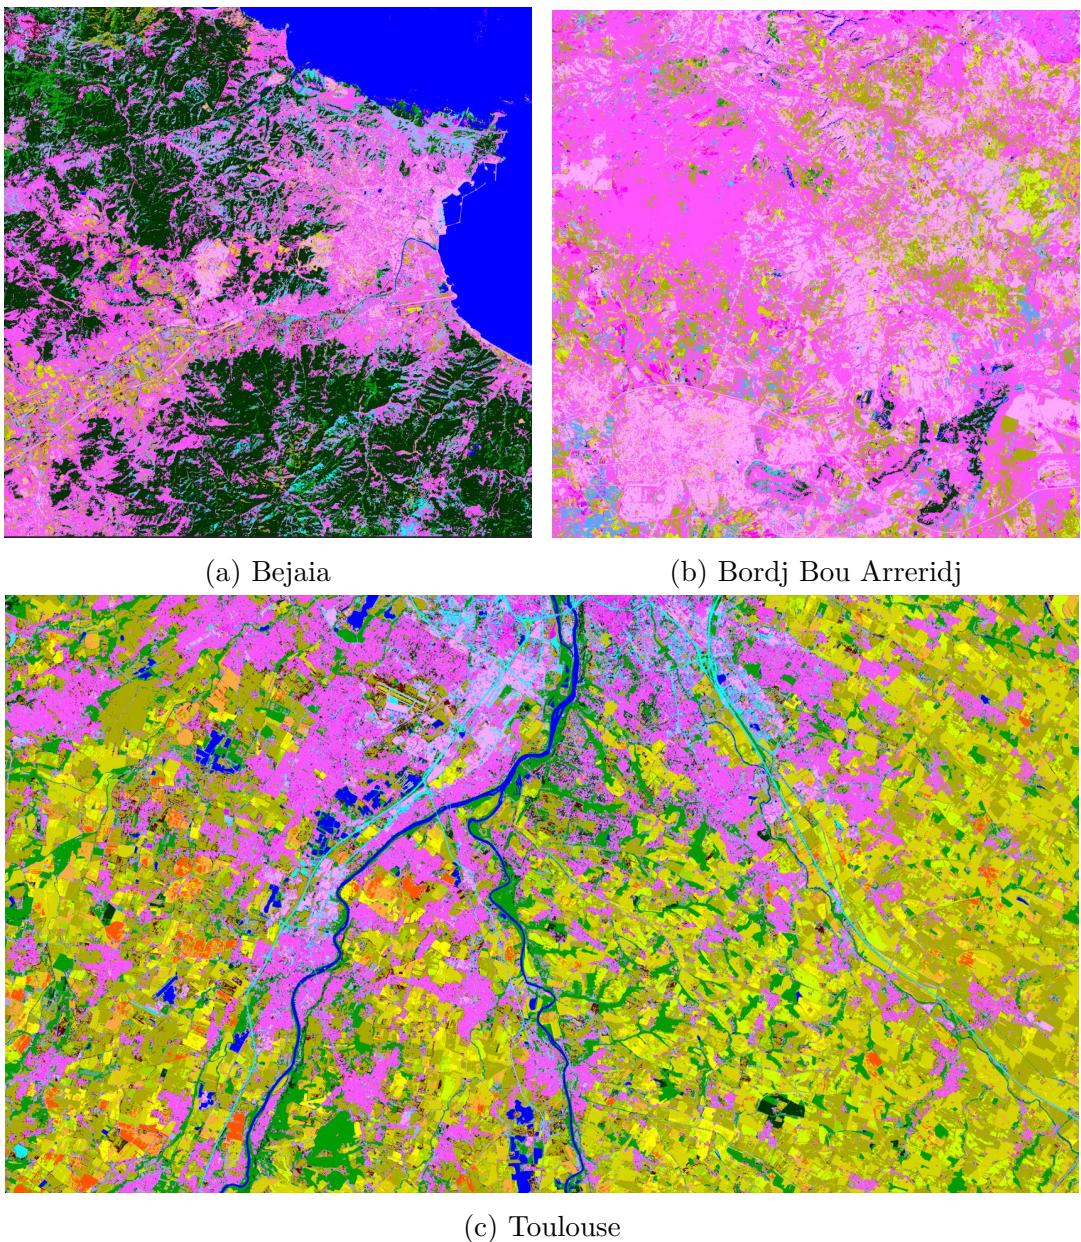


FIGURE A.1 – Premier prototype de carte d'occupation du sol des deux régions

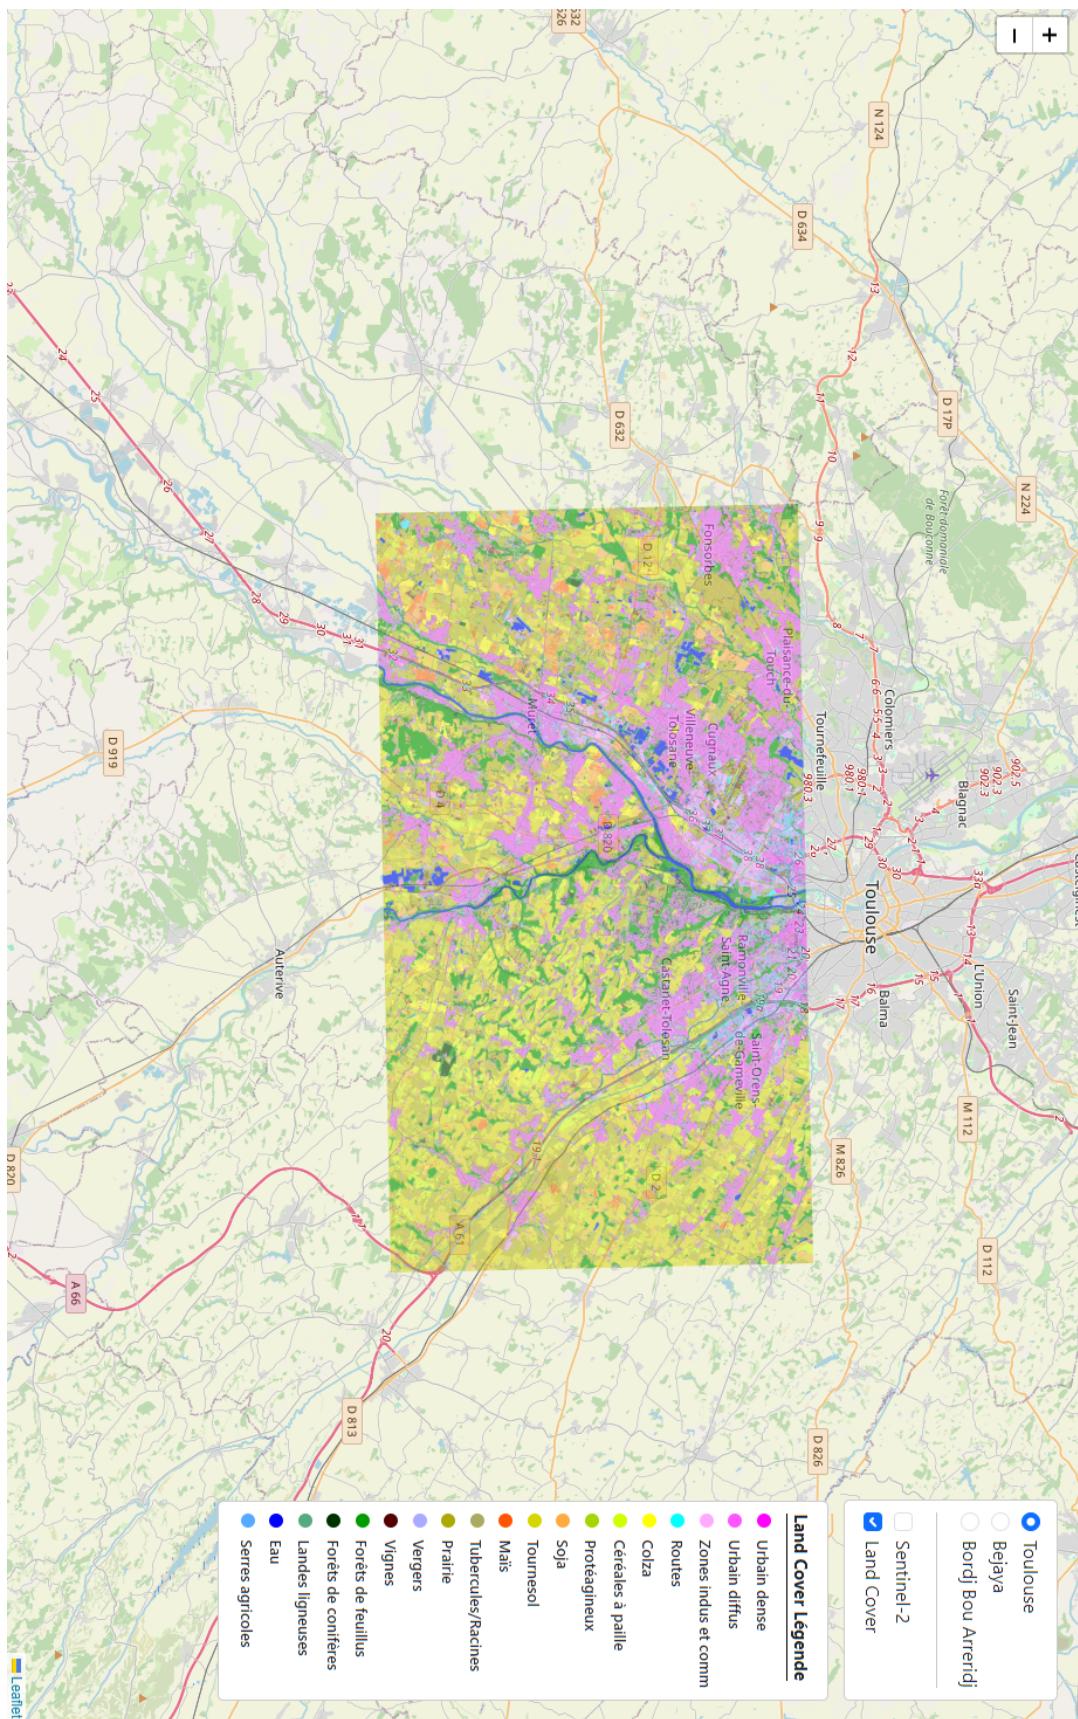


FIGURE A.2 – Présentation du premier prototype sur notre application web

Modèle d'affaires (Business Model Canvas)

Partenaires clés	Activités clés	Propositions de valeur	Relations clients	Segments de clients
<p>1.Fournisseurs de données satellite pour l'accès aux images et aux séries temporelles.</p> <p>2.Collaboration avec des institutions académiques pour fournir un accès à des recherches de pointe et à des experts en géographie.</p>	<p>1.Conception et amélioration continue des algorithmes d'apprentissage profond.</p> <p>2.Mise à jour régulière des bases de données de séries temporelles.</p> <p>3.Collecte et traitement des données satellitaires.</p> <p>4.Analyse des séries temporelles pour détecter les changements d'occupation du sol.</p> <p>5.Développement et maintenance de l'interface web pour la visualisation des cartes.</p>	<p>1.Prédiction des rendements agricoles pour une meilleure planification et augmentation de la productivité.</p> <p>2. Les cartes fournissent des données essentielles pour la gestion des territoires et l'urbanisme.</p> <p>3.Une interface web conviviale permettant aux utilisateurs de visualiser facilement les résultats et les types de sols.</p> <p>4.Cartes d'occupation du sol précises et actualisées basées sur une série temporelle d'images satellite.</p> <p>5.Des cartes mises à jour rapidement pour répondre aux besoins dynamiques des clients</p>	<p>1.Support technique en ligne pour l'intégration et l'utilisation des cartes générées</p> <p>2.Personnalisation des solutions pour répondre aux besoins spécifiques des clients.</p> <p>3.formations sur l'utilisation des cartes.</p>	<p>1.Ministère de l'Agriculture, du Développement Rural et de la Pêche: Ils peuvent utiliser ces informations pour la planification du développement rural, la surveillance des ressources agricoles et la mise en œuvre de politiques agricoles.</p> <p>2.Ministère de l'Environnement et des Énergies Renouvelables:Pour la gestion et la conservation des écosystèmes naturels</p> <p>3.Autorités de Planification Urbaine et Régionale</p> <p>4.Associations Environnementales Locales</p> <p>5.Universités et Institutions de Recherche</p> <p>6.Le Cadastre</p> <p>7.Les Bureaux d'Étude : Planification Urbaine et Rurale , Études Environnementales</p>

	<p>Ressources clés</p> <ol style="list-style-type: none">1.Des spécialistes en intelligence artificielle pour développer et affiner les algorithmes.2.Un expert en géographie3.Développeurs Web : Pour la création et la maintenance de l'interface utilisateur.4.Serveurs puissants pour le stockage et le traitement des données.5.Images Satellitaires : Accès continu à des images satellitaires à haute résolution.6.Infrastructure informatique pour le stockage et le traitement des données (cloud).	<p>Canaux</p> <ol style="list-style-type: none">1.Plateformes en ligne pour la distribution et l'accès aux cartes d'occupation du sol.2.publications et conférences dans des événements spécialisée
	<p>Structure de coûts</p> <ol style="list-style-type: none">1.Coûts de développement et de maintenance des algorithmes et l'interface web2.Salaires de l'équipe de recherche et développement3.Coûts marketing et de vente pour promouvoir les solutions et les services.	<p>Sources de revenus</p> <ol style="list-style-type: none">1.Abonnements pour l'accès aux cartes et aux analyses2.Services de consultation personnalisés